

UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ARTES, CIÊNCIAS E HUMANIDADES
PROGRAMA DE PÓS-GRADUAÇÃO EM SISTEMAS DE INFORMAÇÃO

FELIPE MORINE MAGAMI

**Modelo de detecção de depressão a partir de postagens em português no
Facebook**

São Paulo

2019

FELIPE MORINE MAGAMI

**Modelo de detecção de depressão a partir de postagens em português no
Facebook**

Versão original

Projeto de pesquisa para o exame de qualificação apresentado à Escola de Artes, Ciências e Humanidades da Universidade de São Paulo como parte dos requisitos para obtenção do título de Mestre em Ciências pelo Programa de Pós-graduação em Sistemas de Informação.

Área de concentração: Metodologia e Técnicas da Computação

Orientador: Prof. Dr. Luciano Antonio Digiampietri

São Paulo

2019

Resumo

Magami, Felipe Morine. **Modelo de detecção de depressão a partir de postagens em português no Facebook**. 2019. 64 f. Texto para o Exame de Qualificação (Mestrado em Ciências) – Programa de Pós-Graduação em Sistemas de Informação, Universidade de São Paulo, São Paulo, 2019.

A depressão é um transtorno mental que acomete centenas de milhões de pessoas ao redor do mundo, com consequências potencialmente graves se não tratada. Apesar disso, muitas pessoas continuam a sofrer de depressão sem serem diagnosticadas. Recentemente, o número de trabalhos sobre detecção automática de depressivos tem aumentado. Este mestrado tem como objetivo o desenvolvimento e a avaliação do desempenho de modelos de detecção de depressão a partir do conteúdo textual de postagens em português brasileiro no Facebook que apresente uma taxa de acerto significativamente maior do que a do *baseline* proposto.

Detecção de depressão. Redes Sociais. Mineração de texto.

Abstract

Magami, Felipe Morine. **Depression detection model from Portuguese Facebook posts**. 2019. 64 p. Dissertation Project (Master of Science) – School of Arts, Sciences and Humanities, University of São Paulo, São Paulo, 2019.

Depression is a mental disorder that affects hundreds of millions of people around the world, with potentially serious consequences if left untreated. Despite this, many people continue to suffer from depression without being diagnosed. Recently, the number of works on automatic detection of depressants has increased. This paper aims to develop and evaluate the performance of depression detection models based on the textual content of Brazilian Portuguese posts on Facebook that presents a significantly higher hit rate than the proposed baseline.

Detection of depression. Social networks. Text mining.

Lista de figuras

Figura 1 –	Projeção de vetores para países e capitais criados por um modelo Skip-gram	16
Figura 2 –	Arquitetura geral dos modelos de detecção de depressão	33
Figura 3 –	Taxas de acerto da abordagem baseada na medida TF*IDF para a classificação em quatro níveis de depressão	37
Figura 4 –	Taxas de acerto da abordagem baseada na medida TF*IDF para a classificação em dois níveis de depressão	40
Figura 5 –	Histórico da tramitação do projeto de pesquisa	59
Figura 6 –	Estado de aprovado do projeto de pesquisa	59
Figura 7 –	Parecer completo, liberado pelo comitê de ética - parte 1	60
Figura 8 –	Parecer completo, liberado pelo comitê de ética - parte 2	61
Figura 9 –	Parecer completo, liberado pelo comitê de ética - parte 3	62
Figura 10 –	Parecer completo, liberado pelo comitê de ética - parte 4	63
Figura 11 –	Parecer completo, liberado pelo comitê de ética - parte 5	64

Lista de tabelas

Tabela 1 – Resultados das buscas nas bibliotecas científicas	18
Tabela 2 – Síntese dos artigos selecionados	19
Tabela 3 – Proporção das classes do conjunto de dados	32
Tabela 4 – Taxas de acerto da abordagem baseada no uso de classificadores para os quatro níveis de depressão	38
Tabela 5 – Taxas de acerto da abordagem baseada no uso de classificadores para os dois níveis extremos de depressão	41
Tabela 6 – Cronograma das atividades propostas	42

Sumário

1	Introdução	8
1.1	<i>Objetivo</i>	10
1.2	<i>Hipótese</i>	10
1.3	<i>Justificativa</i>	10
1.4	<i>Organização desde documento</i>	10
2	Conceitos fundamentais	11
2.1	<i>Depressão</i>	11
2.2	<i>Mineração de texto</i>	13
2.2.1	Pré-processamento de texto	14
2.2.2	Linguistic Inquiry and Word Count (LIWC)	15
2.2.3	Métodos de <i>embedding</i>	15
3	Revisão bibliográfica	17
3.1	<i>Resultados e discussão</i>	18
3.1.1	Conjuntos de dados	25
3.1.2	Classificação real dos indivíduos ou postagens depressivas	26
3.1.3	Criação ou extração de atributos	27
3.1.4	Classificadores	29
3.2	<i>Considerações finais sobre a revisão</i>	29
4	Proposta de pesquisa	32
4.1	<i>Estudo de caso</i>	34
4.1.1	Abordagem baseada na frequência relativa das palavras	34
4.1.2	Abordagem baseada na representação BoW	36
4.1.3	Resultados	36
4.2	<i>Plano de trabalho e cronograma</i>	41
5	Considerações finais	43
	Referências¹	44

¹ De acordo com a Associação Brasileira de Normas Técnicas. NBR 6023.

Anexo A – Questionário BDI-II	55
Anexo B – Trâmite do projeto de pesquisa no Comitê de Ética	59

1 Introdução

A depressão é um transtorno caracterizado pela falta de interesse e prazer, tristeza, sentimento de culpa, falta de autoconfiança, cansaço persistente, falta de concentração e distúrbios do sono, entre outros sintomas (NATIONAL INSTITUTE OF MENTAL HEALTH, 2015). Se não tratada, a depressão pode, em casos extremos, levar ao suicídio.

Segundo a Organização Mundial de Saúde (ORGANIZAÇÃO MUNDIAL DE SAÚDE, 2017), em 2017, o número de pessoas com depressão no mundo inteiro foi de mais de 300 milhões de pessoas, número que tende a crescer. No Brasil, os depressivos representam 11,5 milhões da população, uma das maiores taxas de depressão no mundo e a maior da América Latina. Apesar disso, provisões e serviços para suporte e identificação de transtornos mentais em geral ainda são considerados insuficientes (CHOUDHURY *et al.*, 2013). Nos Estados Unidos, uma pesquisa envolvendo mais de trinta mil visitas médicas com adultos, em apenas 4.2% dessas visitas ocorreu triagem para depressão (AKINCIGIL; MATTHEWS, 2017).

Alguns motivos para o subdiagnóstico da depressão incluem uma maior ênfase nos sintomas físicos e não nos sintomas cognitivos e afetivos, medo dos efeitos colaterais dos medicamentos antidepressivos e falta de tempo e preparo profissional (TENG; HUMES; DEMETRIO, 2005). Além disso, muitas vezes os próprios depressivos podem não procurar ajuda, não só pelo preconceito que eles possam vir a sofrer, mas também pela vergonha e estigma que eles sentem por si (TROTZEK; KOITKA; FRIEDRICH, 2019).

Os transtornos mentais podem acarretar em grandes custos, grande parte devido a causas indiretas, como perdas com morte precoce, absenteísmo e presenteísmo (RAZZOUK, 2016a). O trabalho de Evans-Lacko e Knapp (2016) envolvendo oito países da Ásia, América e África, estimou que o custo anual por trabalhador no Brasil envolvendo absenteísmo (ausência no trabalho ou abstenção das atividades associadas) e presenteísmo (presença física no trabalho mas sem produtividade) ligados à depressão é de U\$1.361 e U\$5.788, respectivamente. Levando em conta a força laboral brasileira e as estimativas de prevalência de depressão entre pessoas empregadas, o custo total pode ser de U\$63 bilhões, atrás apenas dos Estados Unidos, com U\$84 bilhões. Mais de 700 mil pessoas morrem por ano por suicídio, uma das principais causas de morte para a faixa etária entre os 15 e 29 anos (ORGANIZAÇÃO MUNDIAL DE SAÚDE, 2017).

Existem várias pesquisas com interesse em detectar automaticamente pessoas potencialmente depressivas com o intuito de facilitar esse diagnóstico e promover maior busca por tratamento. Por exemplo, Alghowinem (2013) descreve uma abordagem multimodal para detecção de depressão utilizando atributos vocais, movimento dos olhos e balanço da cabeça. Similarmente, Jiang *et al.* (2018), Kiss *et al.* (2016) e Yang *et al.* (2016) também utilizaram características acústicas de gravações de falas de depressivos para identificação.

A área de mineração de texto ou mineração de dados textuais, considerada uma extensão da área de mineração de dados, trata da extração de padrões não-triviais ou conhecimento de documentos textuais, envolvendo disciplinas como recuperação de informação, análise de texto, extração de informação, categorização, aprendizado de máquina, entre outras (TAN *et al.*, 1999). Documentos textuais, em geral inerentemente desestruturados e ambíguos, podem ser processados e preparados, comumente envolvendo alguma forma de representação ou transformação numérica, para a construção de modelos preditivos (WEISS; INDURKHYA; ZHANG, 2015).

Vários trabalhos estudam a relação entre linguagem e transtornos mentais (PENNEBAKER; MEHL; NIEDERHOFFER, 2003; SMIRNOVA *et al.*, 2018). Rude, Gortner e Pennebaker (2004) identificaram que universitários americanos depressivos utilizavam a palavra “eu” e palavras relacionadas a emoções negativas com maior frequência. Já Al-Mosaiwi e Johnstone (2018) encontraram palavras “absolutistas”, isto é, palavras com maior grau de polarização, como “absolutamente”, “tudo” e “nunca”, em maior frequência em fóruns de internet relacionados a depressão, ansiedade e ideação suicida do que em outros fóruns.

O Facebook, maior rede social do mundo, desfruta de mais de dois bilhões e meio de usuários ativos e 130 milhões de usuários brasileiros (ABBOT, 2019). Isso leva a crer que uma grande quantidade de dados textuais oriundos de postagens desses usuários é gerada diariamente. Com isso em mente, observa-se a oportunidade de identificar usuários potencialmente depressivos brasileiros analisando suas postagens.

Este projeto propõe a utilização de técnicas de mineração de texto, processamento de língua natural e aprendizado de máquina para a detecção de brasileiros depressivos, a partir de suas postagens no Facebook.

1.1 *Objetivo*

O objetivo deste trabalho é o desenvolvimento e a avaliação do desempenho de modelos de detecção de depressão a partir do conteúdo textual de postagens em português brasileiro no Facebook que apresente uma taxa de acerto significativamente maior do que a do *baseline* proposto.

1.2 *Hipótese*

A hipótese a ser investigada no trabalho proposto é a de que a utilização e, quando apropriada, a combinação de diferentes métodos e estratégias de processamento, extração de características, representação vetorial e classificação para dados textuais, em particular os estudados na revisão bibliográfica, podem ser úteis para a identificação de brasileiros depressivos considerando suas produções textuais, se adaptados para o português. Para verificarmos essa hipótese, utilizaremos métricas de avaliação comuns a outros trabalhos de classificação automática, e esperamos que o melhor modelo construído com tais métodos e estratégias apresente métricas melhores do que a do *baseline* utilizado.

1.3 *Justificativa*

Se nossa hipótese for verificada e nosso objetivo alcançado, o melhor modelo obtido pode servir como o primeiro passo para a implementação de um sistema de auxílio ao diagnóstico de depressão de usuários brasileiros de redes sociais.

1.4 *Organização desde documento*

O restante do trabalho está organizado da seguinte forma. O capítulo 2 descreve os principais conceitos utilizados neste trabalho. O capítulo 3 apresenta a revisão da literatura realizada. Já o capítulo 4 detalha a proposta de pesquisa e o estudo de caso realizado. Por fim, o capítulo 5 contém as considerações finais.

2 Conceitos fundamentais

2.1 Depressão

O conjunto de transtornos depressivos se refere aos transtornos cuja característica em comum é o sentimento de tristeza, vazio ou irritação aliado a alterações físicas e cognitivas, com impactos no funcionamento do indivíduo. Neste trabalho, o termo “depressão” se refere ao distúrbio mental conhecido como Transtorno Depressivo Maior.

Segundo a *American Psychiatric Association* (APA), para ser diagnosticado com depressão, o indivíduo deve apresentar pelo menos cinco dos seguintes sintomas, por um período de duas semanas ou mais, quase todos os dias, na maior parte do dia (APA, 2014):

1. humor depressivo ou irritável ou sentimento de “vazio”;
2. perda de interesse ou prazer nas atividades diárias e especialmente em atividades previamente consideradas gratificantes, incluindo diminuição no desejo sexual;
3. aumento ou redução do apetite ou mudanças de peso sem um motivo claro (como dieta);
4. insônia ou sonolência excessiva;
5. alterações psicomotoras observáveis, como agitação (inquietação) ou retardo (lentidão);
6. fadiga constante sem relação a esforço físico ou diminuição de energia, com impacto no esforço e eficiência na execução de tarefas;
7. sentimento de culpa ou desvalia desmedido, relacionado a uma autoavaliação negativa e irrealista e preocupações excessivas, chegando a proporções delirantes;
8. diminuição na capacidade de pensar, tomar decisões ou se concentrar, frequentemente acompanhada de queda de rendimento acadêmico ou profissional ou dificuldades de memória;
9. pensamentos recorrentes de morte e ideação suicida, que variam desde um desejo de não acordar pela manhã, até planos específicos para suicídio.

Para o diagnóstico de depressão, além de estarem presentes constantemente na vida do indivíduo por duas semanas, os sintomas mencionados devem ter efeito clinicamente significativo no seu sofrimento ou em seu funcionamento (social, profissional, etc.). Ademais, os sintomas não podem ser consequência do uso de substâncias ou outras condições médicas.

A severidade dos sintomas permite categorizar o grau da depressão em três níveis: leve, moderado e grave (POWELL *et al.*, 2008).

Maurer, Raymond e Davis (2018) dividem os fatores de risco para desenvolvimento de depressão em três categorias:

- fatores internos: a incidência de depressão em pessoas do sexo feminino é até três vezes maior do que em homens (APA, 2014). Familiares próximos de depressivos também apresentam maior risco de desenvolver depressão. Além disso, também podemos incluir histórico de ansiedade, baixo autoestima e neuroticismo, traço temperamental que denota maior resposta a estressores, o que resulta em emoções negativas mais frequentes;
- fatores externos: referente ao uso de substâncias e outros transtornos mentais, como de conduta (MAURER; RAYMOND; DAVIS, 2018), comportamento repetitivo envolvendo a violação de direitos básicos de terceiros (APA, 2015), e de personalidade *borderline*, padrão difuso de instabilidade das relações do indivíduo de afeto, com outras pessoas, consigo mesmo, e de impulsividade acentuada;
- eventos adversos: nesta categoria são incluídos eventos estressantes ou traumáticos, como histórico de divórcio, abuso na infância, comorbidades, como doenças cardiovasculares e AIDS, e perda de pessoas próximas como os pais. É importante notar que, em eventos como o diagnóstico de doenças crônicas ou uma perda familiar, o diagnóstico adequado da depressão pode ser dificultado. Por exemplo, o especialista deve ser capaz de diferenciar se o indivíduo está apenas em luto ou se ele realmente apresenta sintomas de um episódio depressivo (APA, 2014).

Embora o transtorno depressivo só possa ser confirmado mediante uma avaliação por um profissional treinado baseada nos critérios citados anteriormente, questionários para triagem de depressivos são bastante utilizados (MAURER; RAYMOND; DAVIS, 2018). Um dos questionários mais aplicados é o Inventário de Depressão de Beck (BDI)(BECK *et al.*, 1961) e sua segunda versão com algumas adaptações (BDI-II) (BECK; STEER; BROWN, 1996), compostos de 21 itens para avaliação da gravidade dos sintomas depressivos. No anexo A se encontra uma transcrição do questionário BDI-II aplicado na coleta de dados para o conjunto utilizado.

2.2 Mineração de texto

Segundo Nisbet, Elder e Miner (2009), a mineração de texto é o processo de se descobrir novas informações a partir de coleções de textos. A mineração de texto se diferencia da área mais abrangente da mineração de dados em razão de que esta última em geral lida com formatos de dados altamente estruturados, em contraste à natureza usualmente desestruturada dos dados textuais (WEISS; INDURKHIA; ZHANG, 2015).

No nível mais básico, a mineração de texto trata da transformação e estruturação dos dados textuais em dados numéricos, de forma a permitir, por exemplo, a aplicação de técnicas de aprendizado de máquina para identificação de padrões (WEISS; INDURKHIA; ZHANG, 2015; NISBET; ELDER; MINER, 2009). Uma das estratégias mais comuns é a representação *Bag-of-Words* (BoW), em que o conjunto das diferentes palavras presentes em um *corpus* corresponde às dimensões (os atributos) da representação (AGGARWAL, 2018). Um BoW binário atribui valores 0 ou 1 para a ausência ou presença de um termo em um determinado documento, respectivamente.

Além de valores binários, podemos utilizar também as frequências dos termos. Uma estratégia comum é o cálculo da formulação *Term Frequency*Inverse Document Frequency* (TF*IDF), conforme a equação:

$$TF * IDF_t = f_t \times \log\left(\frac{D}{D_t}\right) \quad (1)$$

em que o valor TF*IDF para o termo t é sua frequência f_t ponderada pelo logaritmo da quantidade total D de documentos no *corpus* dividida pela quantidade D_t de documentos em que t aparece. A vantagem em utilizar a normalização IDF em vez de apenas considerar a frequência do termo é que termos frequentes mas comuns a vários documentos (como *stopwords*) apresentam valores próximos a zero, enquanto termos relativamente únicos e que aparecem em poucos documentos (e que, portanto, podem ser importantes para a tarefa de interesse) apresentam valores maiores (WEISS; INDURKHIA; ZHANG, 2015).

De forma similar, modelos de n-gramas, em que o texto é representado por sequências de n -palavras que aparecem no *corpus*. Neste caso, um modelo de unigrama, ou seja, em que cada dimensão é representada por uma palavra, corresponde a um BoW (AGGARWAL, 2018).

Uma área de estudo relacionada à mineração de texto é o processamento de língua natural. O seu objetivo geral é a melhor compreensão de línguas naturais pelo uso de técnicas computacionais (HOTH; NÜRNBERGER; PAASS, 2005). Extração de informação, sumarização textual e mineração de opinião são assuntos pertinentes a ambas as áreas de processamento de língua natural e mineração de texto (AGGARWAL, 2018). A seguir descreveremos de forma resumida técnicas e conceitos de mineração de texto e processamento de língua natural relevantes para a nossa proposta.

2.2.1 Pré-processamento de texto

Como mencionado anteriormente, dados textuais são frequentemente originários de ambientes não-estruturados. A etapa de pré-processamento, portanto, se faz necessária para a estruturação dos dados textuais (AGGARWAL, 2018). De modo geral, a primeira técnica utilizada é a de tokenização. Nela, o texto extraído é transformado em *tokens*, sequência de caracteres com significado semântico. Quase sempre, os *tokens* são as palavras encontradas no texto (incluindo repetições), embora termos como “São Paulo”, que perde seu significado original se separado em seus componentes, também devam ser considerados. Para línguas ocidentais, a etapa de tokenização normalmente também compreende as tarefas de remoção de pontuação e a substituição de caracteres delimitadores por espaços em branco (HOTH; NÜRNBERGER; PAASS, 2005).

Além da tokenização, alguns métodos de pré-processamento comumente utilizados são:

- a filtragem de termos que via de regra são pouco discriminativos ou informativos, como *stopwords* e palavras extremamente frequentes nos documentos (HOTH; NÜRNBERGER; PAASS, 2005);
- a radicalização, em que palavras com um radical comum são por ele representados ();
- a lematização, que, de forma similar à radicalização, tenta consolidar as palavras em um radical comum, de forma que este termo representativo se refere à entrada de dicionário das palavras consolidadas (como a forma de um verbo no infinitivo ou um substantivo no singular) (AGGARWAL, 2018);
- *Part-of-Speech* (PoS) *tagging*, em que cada palavra é categorizada de acordo com sua função gramatical no texto, como substantivo, adjetivo e verbo (WEISS; IN-

DURKHYA; ZHANG, 2015). As marcações gramaticais podem então ser utilizadas como atributos para a tarefa computacional de interesse.

2.2.2 Linguistic Inquiry and Word Count (LIWC)

O LIWC é uma ferramenta computacional para análise do uso de palavras de acordo com categorias definidas (TAUSCZIK; PENNEBAKER, 2010), incluindo categorias linguísticas (como de pronomes, artigos, e verbos) e psicológicas (como de emoções positivas e negativas, raiva e tristeza). Essencialmente, o LIWC é um dicionário em que para cada palavra foram atribuídas categorias de acordo com avaliações de especialistas. É possível, então, analisar um texto mapeando suas palavras para as categorias do LIWC e realizando uma contagem de cada categoria, por exemplo.

Uma versão em português do LIWC, baseado no original em inglês, foi criado e disponibilizado. BALAGE FILHO, Pardo e ALUÍSIO (2013), utilizando apenas as categorias de emoção positiva e negativa, compara esta versão traduzida com outros dicionários para a tarefa de classificação de sentimento.


2.2.3 Métodos de *embedding*

Métodos de *word embedding* se referem às diversas técnicas utilizadas para a representação de palavras em um espaço vetorial de números reais, de forma a capturar relações semânticas e sintáticas entre elas (MIKOLOV *et al.*, 2013a). Por exemplo, é desejável que a vetorização produzida possa capturar a analogia “‘rei’ está para ‘rainha’ assim como ‘homem’ está para ‘mulher’”, tal que os vetores de “rei”, “rainha”, “homem” e “mulher”, satisfaçam:

$$\text{vetor}(\text{rei}) - \text{vetor}(\text{rainha}) \approx \text{vetor}(\text{homem}) - \text{vetor}(\text{mulher}) \quad (2)$$

A figura 1 mostra uma projeção bidimensional de vetores criados a partir de um método de *word embedding* chamado Skip-gram (MIKOLOV *et al.*, 2013a). Neste cenário, é possível observar que a distribuição dos vetores gerados conseguiu capturar a relação entre países e suas capitais.

Figura 1 – Projeção de vetores para países e capitais criados por um modelo Skip-gram



Fonte: Mikolov et. al., 2013

Existem vários algoritmos para a criação de vetores de *word embedding*. Entre os mais utilizados estão os modelos *word2vec*, que incluem duas arquiteturas: a *Continuous Bag-of-Words*, treinada para a tarefa de prever uma palavra dada suas palavras vizinhas, e a Skip-gram, em que, dada uma palavra, o modelo tenta adivinhar os seus vizinhos. O trabalho de Hartmann *et al.* (2017) avaliou o desempenho de diversos modelos de *word embedding* treinados em um *corpus* em português, para diferentes tarefas de processamento de língua natural. Além disso, métodos de *embedding* também podem ser generalizados para representação não só de palavras mas também de sentenças, parágrafos e até documentos (LE; MIKOLOV, 2014).

3 Revisão bibliográfica

Com o intuito de entender o estado-da-arte de métodos automatizados para a detecção de potenciais pessoas deprimidas com base em dados textuais realizamos uma revisão sistemática da literatura.

A revisão sistemática da literatura é uma metodologia empregada com o propósito de identificar, avaliar e interpretar pesquisas pertinentes a um tópico, pergunta ou fenômeno de interesse em específico (KITCHENHAM, 2004). Em geral, uma revisão sistemática é dividida em três etapas: o planejamento, em que são definidos os propósitos da revisão, seus objetivos e as perguntas a serem respondidas, bem como detalhes acerca das bibliotecas científicas a serem adotadas e os critérios de seleção de trabalhos; a condução, em que, de acordo com as decisões tomadas no passo anterior, os trabalhos são identificados, selecionados e os dados relevantes são extraídos e sintetizados; e por último, a divulgação, em que os resultados da revisão são documentados e publicados.

Esta revisão teve como objetivo identificar os métodos e técnicas empregados para detecção de depressão a partir de dados de texto. Ela procurou responder às seguintes perguntas:

1. Quais são os métodos e técnicas utilizados para a criação (ou cálculo ou extração) de atributos a partir de dados textuais (incluindo características sobre uso de palavras, gramática e representação vetorial)?
2. Quais são os modelos de classificação¹ utilizados para detecção de depressão a partir de dados textuais?
3. Quais foram os conjuntos de dados textuais utilizados?
4. Como a classificação real foi encontrada (isto é, de que forma os depressivos foram identificados)?

Para a etapa de seleção dos trabalhos relevantes, critérios de inclusão e exclusão foram definidos. O artigo selecionado deve obedecer a todos os critérios de inclusão e a nenhum critério de exclusão. Os critérios são:

¹ Para esta revisão também foram considerados modelos para regressão. Trabalhos que tiveram como resultado predições de pontuação para depressão poderiam ser transformados em classes estabelecendo intervalos para diferentes níveis de depressão, estratégia equivalente aos questionários de diagnóstico de depressão utilizado por profissionais.

- I1. Serão incluídos trabalhos publicados e disponíveis integralmente em bases de dados científicas e acessíveis pelos autores;
- I2. Serão incluídos trabalhos que já possuam aprovação pela comunidade científica (isto é, foram submetidos a um processo de revisão por pares);
- I3. Serão incluídos trabalhos que abordam métodos e técnicas para detecção de depressão a partir de dados textuais;
- E1. Serão excluídos trabalhos que não se referem à tarefa de detecção de pessoas depressivas ou textos com conteúdo depressivo (por exemplo, trabalhos voltados para identificação de artigos científicos sobre depressão em bases médicas);
- E2. Serão excluídos trabalhos que utilizam exclusivamente informações não textuais para a tarefa de detecção de depressão.

As bibliotecas digitais utilizadas para a condução desta revisão foram a IEEE Xplore Digital Library, ACM Digital Library e Scopus. A expressão de busca utilizada foi a expressão “*“depress*” AND (“language” OR “text”)*”. Para as duas primeiras bibliotecas, o filtro “Metadata Only” foi utilizado. Para a biblioteca Scopus a expressão de busca foi aplicada apenas para o título, resumo e palavras-chave, restringindo-se para as áreas de computação, matemática e engenharia. Não foi utilizado refinamento por ano ou critérios de qualidade. As buscas foram realizadas e refeitas entre o período de 27/04/2019 e 17/09/2019. A tabela 1 apresenta a quantidade de trabalhos encontrados com a busca descrita e a quantidade de trabalhos incluídos a partir dos critérios de inclusão e exclusão estabelecidos para cada biblioteca.

Tabela 1 – Resultados das buscas nas bibliotecas científicas

Base	Encontrados	Incluídos
IEEE	128	17
ACM	65	12
Scopus	524	47

Fonte: Felipe Magami, 2019

3.1 Resultados e discussão

Todos os 76 trabalhos incluídos na etapa de condução foram lidos na íntegra e as informações referentes ao objetivo e às perguntas definidas no planejamento foram extraídas. A tabela 2 contém a lista dos trabalhos incluídos e os dados extraídos.

Tabela 2 – Síntese dos artigos selecionados

Referência	Conjunto de dados	Classificação real	Criação de atributos textuais	Modelos de classificação
Oyong, Utami e Luthfi (2018)	Twitter	Anotação por especialistas	PoS <i>tagging</i> e dicionários	Fórmula de pontuação (KARMEN; HSIUNG; WETTER, 2015)
Deshpande e Rao (2017)	Twitter	Não especificado	PoS <i>tagging</i> e BoW	SVM e NB
Morales e Levitan (2016)	Conjunto em AVEC 2014 (VALSTAR <i>et al.</i> , 2014)	BDI-II	LIWC, n-gramas de palavras, caracteres e PoS e métricas de contagem	SVM
Yang, Jiang e Sahli (2018)	AVEC 2016 (VALSTAR <i>et al.</i> , 2016)	PHQ-8	Métodos de <i>embedding</i>	SVM
Katchapakirin <i>et al.</i> (2018)	Facebook	Questionário de saúde mental tailandês	Métricas de contagem, análise de sentimentos e PoS <i>tagging</i>	SVM, florestas randômicas (RF) e redes neurais profundas
Stepanov <i>et al.</i> (2018)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	BoW e métodos de <i>embedding</i>	SVM
Asgari, Shafran e Sheeber (2014)	Gravações de interações entre adolescentes e seus pais	Diagnóstico clínico	Dicionário de valência e excitação ((WARRINER; KUPERMAN; BRYSSBAERT, 2013))	SVM
(FANG <i>et al.</i> , 2014)	Diary.com	Anotação manual	Sintomas do questionário de depressão fornecido na plataforma Psych Central e no Unified Medical Language System (UMLS)	Modelos Bayesianos
Trotzek, Koitka e Friedrich (2019)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Presença do pronome “Eu”, PoS <i>tagging</i> , pontuações de legibilidade, métricas de contagem, expressões selecionadas, nomes de antidepressivos, LIWC e métodos de <i>embedding</i>	CNN (para <i>embedding</i>), LR (para outros atributos) e ensemble
Kang, Yoon e Kim (2016)	Twitter	Expressões específicas	Dicionários de sentimentos (VSO, SentiStrength, WordNet) e de <i>emoicons</i> e PoS <i>tagging</i>	SVM
Tadesse <i>et al.</i> (2019)	Reddit (PIRINA; ÇÖLTEKIN, 2018)	De acordo com grupo de origem das postagens	LIWC, n-gramas e LDA	LR, SVM, RF, AdaBoost e Perceptron multicamadas (MLP)
Correia, Raj e Trancoso (2018)	WSM (TRANCOSO <i>et al.</i> , 2018) e DAIC (GRATCH <i>et al.</i> , 2014)	Anotação manual (WSM) e PHQ-8 (DAIC)	BoW	SVM
Nguyen <i>et al.</i> (2014)	LiveJournal	De acordo com grupo de origem das postagens	ANEW, LIWC, LDA e etiquetas de humor do LiveJournal	Lasso (LR)
Chomutare, Årsand e Hartvigsen (2015)	Comunidades online	Extração automática com verificação manual de sintomas do questionário ICM-I0	N-gramas	SVM, NB e árvores de decisão (DT)

Continua na próxima página

Referência	Conjunto de dados	Classificação real	Criação de atributos textuais	Modelos de classificação
Lam, Dongyan e Lin (2019)	DAIC (GRATCH <i>et al.</i> , 2014)	PHQ-8	BoW, modelagem de tópicos manual e <i>data augmentation</i>	Modelos de redes de trans-formação
Tlachac, Toto e Rundensteiner (2019)	Mensagens de textos e postagens em redes sociais	PHQ-9	Análise de sentimentos com ferramenta TextBlob, avaliação de subjetividade do texto, PoS <i>tagging</i> e métricas de contagem	Algoritmo k-vizinhos mais próximos (KNN), SVM, RF, AdaBoost, XGBoost, LR e NB.
Alghamdi (2019)	Mensagens de textos entre pacientes e psicólogos	Anotação manual	N-gramas	KNN, SVM, gradiente descendente estocástico (SGD), NB, DT, RF e AdaBoost
Yang <i>et al.</i> (2017b)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Métricas de contagem e termos específicos e atributos semânticos relacionados a trechos específicos do conjunto	SVM
Sun <i>et al.</i> (2017)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Atributos semânticos relacionados a trechos específicos do conjunto	RF
Wu, Koh e Chen (2019)	Facebook	Anotação manual	Dicionários chineses de emoção e <i>emoticons</i> e métodos de <i>embedding</i>	Pontuação através dos dicionários e CNN
Sadeque, Xu e Bethard (2018)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, métodos de <i>embedding</i> treinados em n-gramas relacionados à depressão e conceitos médicos	SVM e redes neurais recorrentes (RNN)
Pampouchidou <i>et al.</i> (2016)	AVEC 2016 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Métricas de contagem e palavras depressivas, ANEW e LIWC	DT e ensembles
Yang <i>et al.</i> (2017a)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Atributos semânticos relacionados a trechos específicos do conjunto e métodos de <i>embedding</i>	CNN
Williamson <i>et al.</i> (2016)	AVEC 2016 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Métodos de <i>embedding</i> e atributos semânticos relacionados a trechos específicos do conjunto	CNN
Choudhury <i>et al.</i> (2014)	Facebook	Autodeclaração e PHQ-9	LIWC e palavras relacionadas a perguntas (e.g. “como”, “por quê”)	SVM
Choudhury, Counts e Horvitz (2013)	Twitter	Autodeclaração e CES-D	LIWC, ANEW e n-gramas	SVM
Yazdavar <i>et al.</i> (2017)	Twitter	Expressões específicas com anotação manual por sintomas do PHQ-9	LDA com termos sementes a partir de sintomas do PHQ-9 e palavras relacionadas a depressão	Classificação a partir do modelo de tópicos gerado, SVM e NB
Gupta <i>et al.</i> (2014)	AVEC 2014 (VALSTAR <i>et al.</i> , 2014)	BDI-II	Dicionários próprios de excitação e valência, modelos de distribuição semântica, n-gramas e PoS <i>tagging</i>	SVM
Dang <i>et al.</i> (2017)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	BoW, PoS e n-gramas indexados e dicionários ANEW, EmoLex, SenticNet e Laswell	Regressores Gaussianos e máquinas de vetores relevantes
Continua na próxima página				

Referência	Conjunto de dados	Classificação real	Criação de atributos textuais	Modelos de classificação
(JARROLD <i>et al.</i> , 2010)	Western Collaborative Group Study (ROSENMAN <i>et al.</i> , 1964)	CES-D	PoS <i>tagging</i> , LIWC, avaliador de densidade de ideias (CPIDR) e frequência de palavras em primeira pessoa	LR, MLP
Villatoro-Tello, rosa e Jiménez-Salazar (2017)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Modelagem de grafos de gramas de palavras e letras	Cálculo de medidas de similaridade entre o documento de interesse e os grafos das classes gerados
Ramiandrisoa <i>et al.</i> (2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, PoS <i>tagging</i> , termos de negação, capitalizações, pontuações, <i>emoticons</i> , métricas de contagem, palavras em primeira pessoa, palavras “absolutistas”, termos no pretérito e relacionados, sintomas e medicamentos relacionados a depressão, frequência da expressão “depress*”, n-gramas, análise de sentimentos, termos relacionados a sono, pontuação de legibilidade e métodos de <i>embedding</i>	RF e LR
Orhan, Mercan e Gökgöl (2020)	Conjunto de áudio em turco	Diagnóstico clínico	Radicais, afixos, PoS, análise de sentimentos, dicionário de psicologia Harard-III e BoW	NB, LR Bayesiano e SVM
Sadeque, Xu e Bethard (2017)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Dicionário de palavras relacionadas à expressão regular “depress*” do Yahoo! Respostas e conceitos do UMLS	SVM, RNN e ensemble
Resnik, Garron e Resnik (2013)	Redação de universitários sobre seus sentimentos (RUDE; GORTNER; PENNEBAKER, 2004)	BDI	LDA e LIWC	Regressão linear
Gong e Poellabauer (2017)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	LIWC e atributos semânticos relacionados a trechos específicos do conjunto	RF, SGD e SVM
Burdisso, Errecalde e Montes-Y-Gómez (2019)	eRisk 2019 (LOSADA; CRESTANI; PARAPAR, 2019)	BDI	Framework SS3 (BURDISO; ERRECALDE; GÓMEZ, 2019)	Framework SS3 (BURDISO; ERRECALDE; GÓMEZ, 2019)
Rathner <i>et al.</i> (2018)	Redações em alemão sobre retrospectiva do ano anterior e expectativas para o ano seguinte	BDI-II	LIWC	LR
Continua na próxima página				

Referência	Conjunto de dados	Classificação real	Criação de atributos textuais	Modelos de classificação
(ALMEIDA; BRI-AND; MEURS, 2017)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	N-gramas, PoS <i>tagging</i> , dicionários (SenticNet, medicamentos, doenças relacionadas e drogas) e métricas de contagem	Recuperação de informação com algoritmo baseado em KNN, ensemble de SVM, ensemble de RF, ensemble dos métodos de classificação e de recuperação de informação.
Peng, Hu e Dang (2019)	Sina Weibo	Expressões específicas	Dicionário de emoções, dicionário de emoções para linguagem de internet e dicionário de <i>emoticons</i>	SVM, NB, KNN, DT, ensemble
Ziemer e Korkmaz (2017)	Redações de pessoas com dores crônicas	CES-D	LIWC	LR
Karmen, Hsiung e Wetter (2015)	Psycho-Babble	Anotação de especialistas	Dicionários de sintomas e sinônimos e de palavras frequentes, pronomes e palavras de negação	Pontuação dada por fórmula própria
Zhao, Lin e Huang (2018)	Blog chinês "Tree Hole"	Não especificado	Métricas de contagem, <i>emoticons</i> , palavras em primeira pessoa, padrões chineses nas sentenças e métodos de <i>embedding</i>	SVM e CNN
Wang, Huang e Chen (2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW	CNN
(ORTEGA-MENDOZA <i>et al.</i> , 2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW	SVM
Burdisso, Errecalde e Gómez (2019)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Framework SS3	Framework SS3
Villegas <i>et al.</i> (2017)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, análise semântica concisa, n-gramas e LIWC	NB, RF e DT
Trotzek, Koitka e Friedrich (2017)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, métodos de <i>embedding</i> , pronomes pessoais e possessivos, verbos no pretérito, métricas de contagem e índices de legibilidade	LR e RNN
(FUNEZ <i>et al.</i> , 2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Análise semântica concisa e abordagem similar ao Framework SS3 (BURDISSO; ERRECALDE; GÓMEZ, 2019)	LR, SVM e abordagem similar ao Framework SS3 (BURDISSO; ERRECALDE; GÓMEZ, 2019)
Abed-Esfahani <i>et al.</i> (2019)	eRisk 2019 (LOSADA; CRESTANI; PARAPAR, 2019) e conjunto próprio de universitários de psicologia para treinamento (aprendizado por transferência)	BDI	Modelos de pré-treinamento generativo (GPT) e LIWC	SVM
				Continua na próxima página

Referência	Conjunto de dados	Classificação real	Criação de atributos textuais	Modelos de classificação
Losada e Crestani (2016)	Reddit	Expressões específicas	BoW	LR
Samareh <i>et al.</i> (2018)	AVEC 2017 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Métricas de contagem, dicionário de palavras relacionadas à depressão e dicionário AFINN	RF
Ragheb <i>et al.</i> (2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Métodos de <i>embedding</i> , sentenças positivas e negativas, versão Bayesiana	MLP, SVM e média móvel
Stankevich <i>et al.</i> (2018)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, métodos de <i>embedding</i> , PoS <i>tagging</i> e métricas de contagem	SVM e RF
Trotzek, Koitka e Friedrich (2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, métodos de <i>embedding</i> , pronomes pessoais e possessivos, verbos no pretérito, métricas de contagem, índices de legibilidade, dicionário de medicamentos, frases específicas e LIWC	LR e RNN
Sugandhi e Mahajan (2017)	Transcrição do áudio de casos no MentalHelp.net	Questionários BDI-II e DSM-5	Dicionários baseados no SentiWordNet, PoS, sintomas, palavras de intensidade e de fatores relevantes como família e histórico médico	Pontuação dada por construção de rede semântica
Rijen <i>et al.</i> (2019)	eRisk 2019 (LOSADA; CRESTANI; PARAPAR, 2019)	BDI	Dicionários Multi Perspective Question Answering, WordNet, de desejos sexuais e de distúrbios alimentares, <i>tokens</i> selecionados por informação mútua e medidas de similaridade semântica dadas por vetores de <i>embeddings</i>	LR, limiar de pontuações e ensemble
Yusof, Lin e Gueirin (2018)	LiveJournal	Postagens com a expressão regular “depress*” no título	Dicionários ANEW, MPQA e SentiWordNet	NB e SVM
Alhanai, Ghassemi e Glass (2018)	DAIC ((GRATCH <i>et al.</i> , 2014))	PHQ-8	Métodos de <i>embedding</i>	LR e RNN
Hiraga (2017)	Blogs japoneses	Expressões específicas	N-gramas	NB, SVM e LR
Sadeque, Xu e Bethard (2017)	eRisk 2017 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Dicionário de palavras relacionadas à expressão regular “depress*” do Yahoo! Respostas e conceitos do UMLS	SVM, RNN e ensemble
Fariás-Anzaldúa <i>et al.</i> (2017)	eRisk 2017	Expressões específicas	N-gramas	NB
Nakamura <i>et al.</i> (2014)	Blogs japoneses	Categoria das postagens anotadas pelos autores dos blogs	Palavras-chave do Self-Rating Depression Scale e modalidade gramatical e semântica dos termos em japonês	SVM
Lopez-Otero <i>et al.</i> (2017)	AVEC 2016 (DAIC (GRATCH <i>et al.</i> , 2014))	PHQ-8	Métodos de <i>embedding</i>	SVM e LR
Continua na próxima página				

Referência	Conjunto de dados	Classificação real	Criação de atributos textuais	Modelos de classificação
Trifan e Oliveira (2019)	eRisk 2019 (LOSADA; CRESTANI; PARAPAR, 2019)	BDI	Análise de sentimentos com TextBlob, pronomes pessoais, palavras absolutistas, dicionário de antipressivos e distúrbios mentais e palavras-chave específicas	Pontuação própria
Paul, Kalyani e Basu (2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	BoW, conceitos do UMLS e métodos de <i>embedding</i>	SVM, RF, AdaBoost, LR e RNN
Tung e Lu (2016)	Fórum PPT	Anotação por especialistas	Dicionários de eventos negativos, emoções negativas, sintomas e pensamentos negativos e PoS <i>tagging</i>	Fórmula de pontuação própria
Delahunty, Wood e Arcan (2018)	Reddit (LOSADA; CRESTANI, 2016)	Expressões específicas	Dicionários LIWC, Warriner, NRC e SenticNet 5, índices de legibilidade, frequência do pronome “eu” e métodos de <i>embedding</i>	RF
Ramírez-Cifuentes e Freire (2018)	eRisk 2018 (Reddit (LOSADA; CRESTANI, 2016))	Expressões específicas	Dicionário LWIC e de antidepressivos, palavras absolutistas e n-gramas	LR e RF
Fatima <i>et al.</i> (2019)	Reddit	Grupo de origem e expressões específicas	Dicionário LIWC, palavras absolutistas e métricas de contagem	SVM, MLP e LR
Correia <i>et al.</i> (2018)	WSM (TRANCOSO <i>et al.</i> , 2018)	Anotação manual	BoW e redes neurais recorrentes de tensores para características de sentimento	LR e SVM
Trancoso <i>et al.</i> (2018)	WSM e DAIC (GRATCH <i>et al.</i> , 2014)	Anotação manual (WSM) e PHQ-8 (DAIC)	BoW e redes neurais recorrentes de tensores para características de sentimento	LR e SVM
Nguyen <i>et al.</i> (2017)	LiveJournal	De acordo com grupo de origem das postagens	LDA e LIWC	LR, SVM e NB
Morales, Scherer e Levitan (2017)	AVEC 2014 (VALSTAR <i>et al.</i> , 2014)	BDI-II	BoW e PoS <i>tagging</i>	SVM
Birjali, Beni-Hssane e Erritali (2017)	Twitter	Anotação manual	Similaridade de grafos de sentimentos, auxiliado por WordNet	SVM, KNN e DT
Nguyen <i>et al.</i> (2015)	LiveJournal	De acordo com grupo de origem das postagens	LDA e LIWC	LR
Choudhury <i>et al.</i> (2013)	Twitter	CES-D e BDI	Dicionários LIWC, ANEW, de termos depressivos retirados do Yahoo! Respostas e de antidepressivos	SVM

3.1.1 Conjuntos de dados

Percebe-se que grande parte dos trabalhos se referem a participações em desafios, especificamente os desafios eRisk para detecção precoce de risco na internet dos anos 2017 (LOSADA; CRESTANI; PARAPAR, 2017), 2018 (LOSADA; CRESTANI; PARAPAR, 2018) e 2019 (LOSADA; CRESTANI; PARAPAR, 2019); e Audio/Visual Emotion Challenge and Workshop (AVEC) de 2014 (VALSTAR *et al.*, 2014), 2016 (VALSTAR *et al.*, 2016) e 2017 (RINGEVAL *et al.*, 2017). Para a tarefa eRisk dos anos 2017 e 2018, o conjunto de dados primeiramente proposto em (LOSADA; CRESTANI, 2016) foi adotado, em que postagens do Reddit foram coletadas e os usuários depressivos foram localizados a partir de expressões específicas, como “Fui diagnosticado com depressão”, e verificados manualmente. Como o desafio aborda a detecção precoce, a tarefa é dividida em etapas, em que para cada semana um subconjunto das postagens é disponibilizado e os participantes decidem se devem realizar a classificação de um usuário ou se devem esperar até que novas postagens sejam disponibilizadas, de forma que classificações corretas com menos postagens recebem uma pontuação maior. Para o eRisk 2019, foram propostas algumas mudanças: postagens de redes sociais de usuários foram disponibilizados de forma completa e os participantes tiveram como objetivo prever a pontuação para cada uma das perguntas encontradas no Inventário de Depressão de Beck (BDI) (BECK *et al.*, 1961).

Os conjuntos de dados utilizados pelo desafio AVEC são de gravações de interações humano-computador. Em particular, o conjunto Distress Analysis Interview Corpus (DAIC) (GRATCH *et al.*, 2014), adotado nas tarefas de 2016 e 2017, também foi utilizado por outros estudos (CORREIA; RAJ; TRANCOSO, 2018; LAM; DONGYAN; LIN, 2019; ALHANAI; GHASSEMI; GLASS, 2018). Por causa da natureza dos dados, alguns trabalhos do AVEC e de conjuntos de áudio e vídeo tendem a focar menos nos atributos textuais. Trabalhos como os de Yang *et al.* (2017b) e Sun *et al.* (2017) utilizam informações semânticas sobre conteúdo próprio do DAIC, como se o participante já foi diagnosticado previamente com depressão ou estresse pós-traumático e se ele sofre de problemas de sono, combinadas com outras características como gestos e movimentação da cabeça e segmentação de voz.

Analisando os artigos não-relacionados às estes desafios, observamos que a maior parte dos conjuntos são oriundos de dados online, em particular de redes sociais, como Twit-

ter (OYONG; UTAMI; LUTHFI, 2018; DESHPANDE; RAO, 2017; KANG; YOON; KIM, 2016; CHOUDHURY; COUNTS; HORVITZ, 2013; YAZDAVAR *et al.*, 2017; BIRJALI; BENI-HSSANE; ERRITALI, 2017; CHOUDHURY *et al.*, 2013), Facebook (KATCHAPAKIRIN *et al.*, 2018; WU; KOH; CHEN, 2019; CHOUDHURY *et al.*, 2014) e LiveJournal (NGUYEN *et al.*, 2014; YUSOF; LIN; GUERIN, 2018; NGUYEN *et al.*, 2017; NGUYEN *et al.*, 2015). Um conjunto interessante é o in-the-Wild Speech Corpus (WSM), coletado em (TRANCOSO *et al.*, 2018) e utilizado também por (CORREIA; RAJ; TRANCOSO, 2018) e (CORREIA *et al.*, 2018), de vídeos do YouTube sobre um determinado tema. Embora o foco do estudo não seja só em depressão, vídeos sobre depressão foram coletados pela expressão “vlog de depressão” e verificados manualmente.

3.1.2 Classificação real dos indivíduos ou postagens depressivas

Sobre os métodos utilizados para identificar as classes reais, isto é, se o indivíduo ou postagem apresenta ou não conteúdo depressivo, foram identificadas duas abordagens diferentes: uma que inclui o contato direto (pessoalmente, por questionários, etc) com a pessoa que produziu os dados e outra sem nenhum contato (com base, por exemplo, no conteúdo textual ou informações de contexto).

No caso das anotações sem contato/envolvimento, os usuários ou postagens são identificados em geral se apoiando em algum tipo de estratégia, como procurar por sintomas depressivos específicos, como em Fang *et al.* (2014), ou por expressões específicas, como em Losada e Crestani (2016) descrito anteriormente. Alguns trabalhos também separam grupos depressivos de não depressivos de acordo com sua origem, como em Nguyen *et al.* (2014), em que as postagens são categorizadas de acordo com o grupo do LiveJournal de origem (depressão, bipolaridade, separação, suicídio e auto-mutilação para o grupo clínico e animais de estimação, moda, comida, parentalidade e tecnologia para o grupo de controle), ou em (NAKAMURA *et al.*, 2014), em que postagens em blogs já estavam categorizados de acordo com *tags* colocadas pelos próprios autores dos blogs.

Para os conjuntos anotados com envolvimento dos autores dos textos a estratégia mais utilizada é a aplicação de questionários autoavaliativos, frequentemente aplicados por psicólogos para auxílio ao diagnóstico. Os questionários mais populares nesta revisão foram o Patient Health Questionnaire com oito (KROENKE *et al.*, 2009) e nove (KROENKE;

SPITZER, 2002) itens (PHQ-8 e PHQ-9, respectivamente), o mesmo utilizado no DAIC; o Beck Depression Inventory (BECK *et al.*, 1961) (BDI) e sua segunda versão (BECK; STEER; BROWN, 1996) (BDI-II); e o Center for Epidemiologic Studies - Depression (CES-D).

Segundo Losada e Crestani (2016), o motivo de se utilizar anotações automáticas ou manuais, sem envolvimento com os autores dos textos depressivos, é que justamente esse contato pode ser tedioso, e isso pode limitar a qualidade e volume dos dados, ainda que isso possa degradar a qualidade das classificações corretas (não se pode garantir, por exemplo, que uma postagem sem conteúdo depressivo aparente não tenha sido escrito por uma pessoa com depressão). Para os conjuntos de dados de vídeo, com exceção do WSM, por ser de vídeos do Youtube, a aplicação de questionários é frequente possivelmente por este contato direto com os participantes dos vídeos ser normalmente inevitável. Trabalhos como os de Tlachac, Toto e Rundensteiner (2019), Choudhury *et al.* (2014) e Choudhury *et al.* (2013) utilizaram uma abordagem de *crowdsourcing* em que, ao mesmo tempo em que são recrutados participantes dispostos a disponibilizar suas publicações em redes sociais para comporem o *corpus* do estudo, os *crowdworkers* devem responder aos questionários de depressão. Mesmo assim, no trabalho de Choudhury *et al.* (2014) para detecção de mulheres com depressão pós-parto no Facebook, participantes que foram diagnosticadas como tendo depressão pelo questionário PHQ-9 mas que declararam não ter diagnóstico prévio de depressão foram descartadas para evitar essa discrepância. É importante notar que apenas os participantes dos trabalhos de Orhan, Mercan e Gökgöl (2020) de transcrições de áudio de pessoas de uma clínica psiquiátrica e Asgari, Shafran e Sheeber (2014) de gravações de interações entre adolescentes e seus pais foram avaliados clinicamente para serem diagnosticados como depressivos ou não. Isso se deve, provavelmente, pelas dificuldades mencionadas anteriormente.

3.1.3 Criação ou extração de atributos

Diversos métodos de criação/extração de características textuais para serem aplicadas a modelos de aprendizado de máquina foram observados. Técnicas habitualmente utilizadas em outras tarefas de processamento de língua natural e mineração de texto, como BoW, n-gramas e PoS *tagging* foram observadas com frequência. O uso de PoS *tagging* para depressão é particularmente interessante, já que alguns estudos já verificaram

singularidades no uso da língua por depressivos, como maior uso de pronomes em primeira pessoa (RUDE; GORTNER; PENNEBAKER, 2004) e verbos no pretérito (TRIFU *et al.*, 2017). Karmen, Hsiung e Wetter (2015) realizam classificação a partir da pontuação dada por uma fórmula baseada em palavras de frequência (como “sempre”, “nunca” e “geralmente”), sintomas depressivos, pronomes e negações. Tal abordagem também foi utilizada por Oyong, Utami e Luthfi (2018).

Dicionários voltados para a aplicação em computação, como o Linguistic Inquiry and Word Count (LIWC) (TAUSCZIK; PENNEBAKER, 2010), com categorias relacionadas a PoS, análise de sentimentos e interesses pessoais, e o Affective Norms for English Words (ANEW) (BRADLEY; LANG, 1999), para valência e excitação afetiva das palavras também foram frequentemente empregados. Realizar uma análise de emoções nos textos pode ser útil levando em conta o impacto emocional que a depressão provoca. Alguns trabalhos também utilizaram dicionários de criação própria, como os dicionários de Karmen, Hsiung e Wetter (2015) para termos de frequência e sintomas. O uso de modelagem de tópicos a partir da técnica Latent Dirichlet Allocation (TADESSE *et al.*, 2019; NGUYEN *et al.*, 2014; YAZDAVAR *et al.*, 2017; RESNIK; GARRON; RESNIK, 2013; NGUYEN *et al.*, 2017; NGUYEN *et al.*, 2015) não foi tão comum quanto o das outras técnicas.

Métodos de *word embedding*, que ganharam popularidade após a introdução do *word2vec* (MIKOLOV *et al.*, 2013a), também são bastante frequentes em trabalhos mais recentes. Os modelos de *embedding* adotados são variados; Stepanov *et al.* (2018) fazem uso de modelos do *word2vec* treinados em dados do Google News, já (YANG; JIANG; SAHLI, 2018) utiliza *embedding* de parágrafo, enquanto (LOPEZ-OTERO *et al.*, 2017) emprega vetores pré treinados do GloVe (PENNINGTON; SOCHER; MANNING, 2014).

O trabalho de Ramianandrisoa *et al.* (2018) utiliza a maioria das abordagens de extração de atributos textuais encontradas. Vários modelos foram criados para a participação no eRisk 2018, a partir de duas abordagens: uma baseada em características, que inclui BoW, frequência de PoS, termos de negações, capitalizações, pontuação, *emoticons*, métricas de contagem, como quantidade de postagens e comentários, palavras em primeira pessoa, palavras “absolutistas”, como mencionado anteriormente, expressões temporais remetendo ao passado, sintomas e medicamentos relacionados à depressão, frequência da expressão “depress*”, n-gramas selecionados por relevância, análise de sentimentos, termos relacionados ao sono, análise de legibilidade do texto e métodos de *embedding doc2vec* (LE;

MIKOLOV, 2014), treinados utilizando modelos de floresta randômica (RF) e regressores logísticos (LR).

3.1.4 Classificadores

Embora tenha sido observada uma grande variedade de modelos de classificação e regressão, os mais utilizados foram a máquina de vetores-suporte (SVM) e LR. Métodos de árvores e modelos baseados em algoritmos Bayesianos como Naive Bayes (NB) também foram bastante utilizados. Redes neurais convolutivas (CNN) também foram frequentes em trabalhos quando vetores de *embedding* foram utilizados. Curiosamente, alguns trabalhos não utilizaram modelos de aprendizado de máquina clássicos como a maioria, por exemplo, o uso de uma fórmula de pontuação proposto por Karmen, Hsiung e Wetter (2015), mencionado anteriormente, e a abordagem SS3 apresentada por Burdisso, Errecalde e Gómez (2019) e também em outros trabalhos (BURDISSO; ERRECALDE; MONTES-Y-GÓMEZ, 2019; RAZZOUK, 2016b).

Na abordagem SS3, o texto é dividido em subníveis composto de partes de subníveis inferiores e, para cada parte de um subconjunto, é calculado um valor de confiança de “pertencimento” daquela parte em cada classe, como um valor indicando que a palavra “apple” (“maçã”) tem certo pertencimento às classes “comida” e “tecnologia”, mas pouco pertencimento à classe “viagem”. Este valor de confiança leva em consideração a frequência da palavra na classe, a partir de textos coletados anteriormente, e ponderada por termos que tentam diminuir este valor de acordo com o valor de confiança para outras classes, de forma que as palavras não tenham valores altos para muitas classes e *stop words* tenham valor próximo de zero para todas as classes. As partes são então combinadas em seus níveis até que um valor para cada classe seja dado para o documento a ser classificado.

3.2 Considerações finais sobre a revisão

Este capítulo apresentou uma revisão sistemática da literatura para identificar trabalhos relacionados à detecção de depressão a partir de dados textuais. Mais especificamente, objetivou-se identificar os métodos e técnicas computacionais empregados, bem como os conjuntos de dados utilizados. Com a depressão como assunto em voga e com

espaço para o aprimoramento das ferramentas de auxílio ao diagnóstico atuais, espera-se que este trabalho possa incentivar novas pesquisas para a área investigada.

Observou-se que competições de detecção de depressão incentivaram o desenvolvimento desta área. Um grande parcela dos trabalhos encontrados está relacionada aos desafios propostos pelo eRisk e pelo AVEC. Fora do escopo dessas competições, os dados utilizados são predominantemente originários de fóruns e redes sociais online, com quase nenhuma disponibilização pública dos dados. A língua predominante dos conjuntos utilizados é a inglesa e, embora outras línguas, como a chinesa, tenham sido observadas. Não foi encontrado nenhum trabalho utilizando textos em português.

Os métodos de classificação real são variados. A utilização de anotação manual e automática a partir de estratégias como busca por expressões específicas é popular, mas é mais vulnerável a erros. Uma estratégia mais rigorosa, como uma avaliação clínica dos autores dos textos, é muitas vezes laboriosa e dificulta a coleta de um grande número de amostras. Questionários de depressão podem ser um bom meio-termo, mas mesmo assim podem ser falíveis. Levando isso em conta, uma solução seria a criação e disponibilização de um grande conjunto de dados com um método de classificação real dos dados confiável. Não só isso encorajaria mais trabalhos relacionados à área, como também estabeleceria uma forma de comparação de desempenho para os diferentes métodos de processamento de texto e classificação encontrados fora do escopo dos desafios mencionados.

Para conjuntos de transcrição de áudio, é comum a aplicação de questionários para a identificação do nível de depressão de cada participante, mas, para conjuntos de redes sociais e fóruns, outras alternativas também são frequentes, como a anotação manual por especialistas, expressões específicas e o uso do próprio tópico do fórum de origem.

As técnicas para transformação dos textos em atributos para aplicação em métodos de aprendizado de máquina para classificação ou regressão também são diversas, mas observa-se o grande uso de estratégias convencionais da área de processamento de língua natural, como BoW, análise de sentimentos, uso de dicionários e *word embeddings*. Nota-se, contudo, que é frequente o uso de características textuais mais específicas para depressão, como o uso de dicionários de antidepressivos e conceitos médicos. O uso de características relacionadas a pronomes pessoais e palavras “absolutistas” também são comuns, justificado por observações empíricas de estudos relacionando depressão e linguística, como mencionado anteriormente.

Os métodos de classificação e regressão mais utilizados foram SVM, LR, modelos Bayesianos e métodos de árvores. Além disso, para trabalhos que utilizaram vetorização por *embeddings*, CNNs foram bastante adotadas.

4 Proposta de pesquisa

Neste capítulo é detalhada a proposta de pesquisa, descrevendo os materiais, métodos e ferramentas pretendidos e as etapas a serem cumpridas para o desenvolvimento dos modelos de detecção de depressão para postagens em português no Facebook.

O conjunto de dados a ser utilizado neste trabalho é o mesmo produzido por Caregnato (2018). Ele é composto por postagens no Facebook de 688 voluntários brasileiros, maiores de idade e com contas de Facebook ativas. Foi utilizado um aplicativo próprio batizado de *Vivamente*, em que os voluntários concordavam com as solicitações de permissão do aplicativo e suas postagens eram então coletadas. O trâmite do projeto de pesquisa de Caregnato (2018) no Comitê de Ética em Pesquisa com Seres Humanos do Instituto de Psicologia da USP está detalhado no anexo B. Os voluntários responderam ao questionário BDI-II (ver anexo A), e foram classificados em quatro níveis de depressão, de acordo com a pontuação atingida: mínimo (ou sem depressão), leve, moderado e grave. A tabela 3 apresenta as frequências de cada classe no conjunto.

Tabela 3 – Proporção das classes do conjunto de dados

Classe (nível de depressão)	Frequência
Mínima	27,62%
Leve	11,05%
Moderada	11,05%
Grave	50,29%

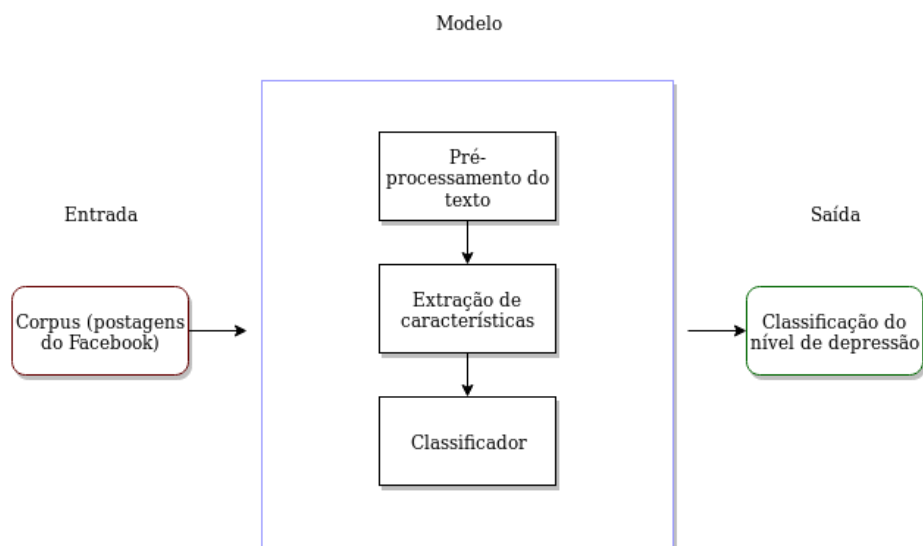
Fonte: Felipe Magami, 2019

A figura 2 apresenta uma visão geral da arquitetura dos modelos a serem construídos. Os modelos seguirão as seguintes etapas de processamento:

1. Pré-processamento: as postagens do conjunto de dados adotado serão primeiramente pré-processados utilizando técnicas de tokenização, filtragem e radicalização;
2. Extração de características: nesta etapa, é proposta a utilização de três abordagens:
 - PoS: considerando as várias evidências de diferenças em padrões linguísticos em textos de depressivos (PENNEBAKER; MEHL; NIEDERHOFFER, 2003; SMIRNOVA *et al.*, 2018; RUDE; GORTNER; PENNEBAKER, 2004), especialmente em relação a pronomes e palavras em primeira pessoa, informações morfossintáticas das postagens podem ser bastante informativas para discriminar os usuários depressivos dos saudáveis;

- LIWC: por motivos similares, palavras relacionadas a sentimentos e emoções podem ser bastante informativas no contexto de detecção de depressão. Além disso, categorias de processos sociais, como “amigos” e “família”, cognitivos e biológicos, por exemplo, podem estar relacionados a sintomas e fatores de riscos depressivos. O LIWC também foi escolhido por ter uma versão traduzida para português (BALAGE FILHO; PARDO; ALUÍSIO, 2013);
 - *Word embeddings*: modelos de *embeddings* têm se tornado populares devido a sua eficiência em modelar palavras e suas relações entre si e por apresentar bons resultados, como em (TROTZEK; KOITKA; FRIEDRICH, 2019). Para este trabalho, pretendemos utilizar modelos pré-treinados em *corpora* em português (HARTMANN *et al.*, 2017);
3. Classificação: os métodos de aprendizado de máquina considerados serão o SVM, por ter apresentado um bom desempenho em alguns dos trabalhos (CORREIA *et al.*, 2018; CHOUDHURY *et al.*, 2013), e CNN para características de *embeddings*, mas é possível que sejam adotados outros classificadores também, como algoritmos bayesianos ou baseados em árvore.

Figura 2 – Arquitetura geral dos modelos de detecção de depressão



Fonte: Felipe Magami, 2019

Os modelos serão testados utilizando uma abordagem de validação cruzada em dez partes (*10-fold cross validation*) e seus desempenhos serão comparados utilizando testes estatísticos.

4.1 Estudo de caso

Para corroborar a proposta, constatar sua factibilidade e para se obter um *baseline* de comparação para os modelos pretendidos, um estudo de caso foi realizado. Nestes estudo foram considerados dois métodos de mineração de textos para a classificação automática das postagens de uma pessoa em quatro níveis de depressão. O primeiro método é baseado no cálculo da frequência relativa das palavras em relação a diferentes conjuntos de dados. Ele consiste em uma variação da abordagem TF*IDF e do uso dessa medida para a classificação das postagens. A segunda abordagem é baseada na representação das postagens no formato vetorial, como um BoW e na utilização dessa representação como entrada para algoritmos de classificação em inteligência artificial. Apenas para efeitos de comparação no escopo deste estudo de caso a classe majoritária foi escolhida como *baseline*.

Para ambas abordagens as postagens de cada pessoa foram concatenadas como um único texto e o resultado do questionário foi utilizado para classificar cada pessoa em um dos quatro possíveis níveis de depressão considerados.

Adicionalmente, dois cenários para cada abordagem foram executados. No primeiro, todos os dados da amostra foram utilizados considerando quatro possíveis níveis de depressão. Já no segundo, foram utilizadas as informações apenas das pessoas cujas respostas ao formulário as classificaram como nos níveis extremos de depressão considerados (menor e maior).

4.1.1 Abordagem baseada na frequência relativa das palavras

Na abordagem baseada na frequência relativa das palavras foi utilizada uma variação da medida TF*IDF. Para cada classe c (ou, neste caso, nível de depressão) e para cada termo t pertencente ao conjunto de postagens de uma pessoa P é realizado o somatório do logaritmo da frequência desse termo no conjunto de todas as postagens classificadas como pertencentes à classe atual (TF_t^c) dividida pela frequência do respectivo termo entre todas as postagens de todas as classes (DF_t) mais 1 (um). Esta somatória é dividida pelo número total de termos utilizadas nas postagens da pessoa P ($\#P$), conforme a equação:

$$TF * IDF_P^c = \frac{\sum_{t \in P} \log\left(\frac{TF_t^c}{DF_t} + 1\right)}{\#P} \quad (3)$$

Desta forma, o conjunto de postagens de cada pessoa receberá um valor para cada uma das classes em análise no presente estudo (isto é, para os quatro níveis de depressão, ou para os dois níveis mais extremos). A estratégia utilizada para este cálculo de forma a evitar a influência das postagens de uma pessoa no cálculo de suas medidas foi a *leave-one-out*, isto é, antes do cálculo das medidas relacionadas a uma pessoa, todas as suas postagens são removidas tanto do corpus contendo todas as postagens de uma dada classe quanto do corpus composto por todas as postagens de todas as pessoas. Após este cálculo, as postagens da pessoa são reinseridas nos respectivos *corpora*.

Para cada pessoa são calculados quatro valores (utilizando os quatro níveis de depressão considerados neste trabalho) ou dois valores (considerando os valores extremos). Para problemas com mais de duas classes, pode se utilizar o maior desses valores para classificar a respectiva pessoa como pertencendo à classe desse problema. Já para problemas binários (com apenas duas classes) é possível utilizar estes valores de três maneiras diferentes para a classificação: o valor máximo entre os dois calculados para a respectiva pessoa; um limiar para um dos valores, a partir do qual a pessoa será classificada como pertencente à respectiva classe; o uso da relação entre os dois valores, isto é, dados os valores $TF * IDF_{P1}^{c1}$ (valor atribuído à classe $c1$ para a pessoa $P1$) e $TF * IDF_{P1}^{c2}$ uma medida derivada é calculada, conforme a equação:

$$ratio_P = \frac{TF * IDF_P^{c1}}{TF * IDF_P^{c1} + TF * IDF_P^{c2}} \quad (4)$$

e um limiar pode ser estabelecido para a medida *ratio*, a partir do qual a pessoa será classificada como pertencente à classe $c1$ e, caso contrário, à classe $c2$.

Estas três abordagens de classificação foram testadas no presente trabalho. Adicionalmente, diferentes estratégias de pré-processamento foram utilizadas antes das postagens serem utilizadas para o cálculo da frequência de seus termos. As abordagens consideradas foram: remoção (ou não) de *stopwords* em português, uso ou não de radicalização para o português e exclusão de palavras com número pequeno de letras. O número mínimo de letras necessárias considerado variou de 1 (manter todas as palavras) até dez (manter apenas palavras com dez ou mais letras). Adicionalmente, foram considerados termos de uma palavra, duas palavras e três palavras (unigramas, bigramas e trigramas). Desta forma, 120 combinações de estratégias de pré-processamento foram testadas para cada uma das três abordagens de classificação mencionadas.

4.1.2 Abordagem baseada na representação BoW

Na abordagem baseada em BoW, o conjunto de postagens de cada pessoa é representado como um conjunto não ordenado de palavras. Este conjunto pode ser visto como um vetor de características e ser utilizado por, por exemplo, classificadores. Neste trabalho, foram utilizados vetores de características binários para representar a presença ou não de uma palavra no conjunto de postagens de cada pessoa. Além do uso de unigramas, foram também considerados vetores de bigramas e trigramas.

O conjunto desses vetores gerou matrizes de características que foram utilizadas por técnicas de inteligência artificial para a classificação das pessoas de acordo com os níveis de depressão. Duas estratégias foram utilizadas: a classificação utilizando todas as características (unigramas, bigramas ou trigramas) e a classificação após o uso de seletores de características, isto é, inicialmente foi utilizado um método de pré-processamento para selecionar as características mais significativas e, em seguida, foram utilizados classificadores considerando apenas estas características.

A estratégia de validação utilizada foi *10-fold cross-validation*, isto é, o conjunto de dados foi dividido aleatoriamente em dez subconjuntos e dez execuções foram realizadas. Em cada uma das execuções, nove subconjuntos foram utilizados para o treinamento do modelo e o outro subconjunto para o teste da abordagem.

O seletor de características utilizado foi o Correlation-based feature Subset Selection (CfsSubsetEval) (HALL, 1999) que objetiva selecionar um subconjunto de características forma a maximizar a correlação entre as características selecionadas e a classe do problema em estudo e, ao mesmo tempo, minimizar a correlação entre as características selecionadas (de forma a minimizar a redundância existente entre elas).

O classificador utilizado neste estudo foi o BayesNet, um classificador baseado no teorema de Bayes que utiliza modelos probabilísticos representados como grafos direcionados acíclicos (KORB; NICHOLSON, 2010).

4.1.3 Resultados

Considerando-se os quatro níveis de depressão analisados no presente estudo, observa-se que a classe majoritária possui de 50,29% das pessoas da amostra. Assim, este valor

será considerado o *baseline* para o presente estudo. A figura 3 apresenta as taxas de acerto da classificação considerando a combinação das diferentes técnicas de pré-processamento utilizadas: remoção ou não de *stopwords*, radicalização, remoção de palavras pequenas e uso de unigramas, bigramas ou trigramas. A abordagem utilizada baseada na frequência relativa das palavras, conforme apresentada na seção anterior, atribuiu uma nota para cada classe ao conjunto de postagens de cada pessoa e esse conjunto foi classificado de acordo com a classe que obteve a maior nota.

A maior taxa de acerto presente na figura 3 é de 68,94% e foi atingida utilizando unigramas, sem a remoção de *stopwords*, sem a utilização de radicalização e excluindo-se os termos com menos de dez letras.

Figura 3 – Taxas de acerto da abordagem baseada na medida TF*IDF para a classificação em quatro níveis de depressão

		Letras Mínimas	Unigrama	Bigrama	Trigrama	Unigrama	Bigrama	Trigrama
			Max	Max	Max	Max	Max	Max
sem radicalização	com remoção de stopwords sem remoção de stopwords	1	61,39%	61,39%	63,13%	59,51%	61,39%	62,70%
		2	61,54%	59,80%	62,99%	59,07%	59,94%	62,70%
		3	61,10%	56,02%	62,55%	59,36%	55,88%	61,39%
		4	61,25%	55,59%	62,41%	62,26%	52,83%	61,39%
		5	61,39%	53,41%	61,54%	64,44%	47,90%	58,78%
		6	63,72%	51,23%	58,49%	65,46%	47,46%	57,18%
		7	65,75%	46,88%	56,17%	64,88%	45,43%	48,62%
		8	66,18%	47,02%	55,30%	64,44%	44,56%	47,90%
		9	65,46%	47,31%	50,51%	63,43%	44,41%	47,17%
		10	68,94%	45,72%	46,15%	64,15%	46,88%	48,19%
	com remoção de stopwords	1	61,39%	57,18%	62,99%	60,38%	60,23%	62,55%
		2	61,25%	56,75%	62,26%	59,94%	59,51%	61,97%
		3	60,38%	55,88%	62,41%	59,22%	56,02%	61,25%
		4	61,25%	55,59%	62,12%	60,38%	52,98%	61,39%
		5	60,67%	53,56%	61,68%	62,12%	47,75%	58,78%
		6	62,41%	51,52%	58,20%	63,86%	47,46%	57,18%
		7	63,43%	46,59%	56,02%	63,57%	45,43%	48,62%
		8	64,01%	47,02%	55,59%	62,41%	44,56%	47,90%
		9	63,28%	47,31%	50,36%	62,41%	44,41%	47,17%
		10	66,04%	45,72%	46,15%	63,43%	46,88%	48,19%
com radicalização	com remoção de stopwords	1	61,39%	61,39%	63,13%	59,51%	61,39%	62,70%
		2	61,54%	59,80%	62,99%	59,07%	59,94%	62,70%
		3	61,10%	56,02%	62,55%	59,36%	55,88%	61,39%
		4	61,25%	55,59%	62,41%	62,26%	52,83%	61,39%
		5	61,39%	53,41%	61,54%	64,44%	47,90%	58,78%
		6	63,72%	51,23%	58,49%	65,46%	47,46%	57,18%
		7	65,75%	46,88%	56,17%	64,88%	45,43%	48,62%
		8	66,18%	47,02%	55,30%	64,44%	44,56%	47,90%
		9	65,46%	47,31%	50,51%	63,43%	44,41%	47,17%
		10	68,94%	45,72%	46,15%	64,15%	46,88%	48,19%
	com remoção de stopwords	1	61,39%	57,18%	62,99%	60,38%	60,23%	62,55%
		2	61,25%	56,75%	62,26%	59,94%	59,51%	61,97%
		3	60,38%	55,88%	62,41%	59,22%	56,02%	61,25%
		4	61,25%	55,59%	62,12%	60,38%	52,98%	61,39%
		5	60,67%	53,56%	61,68%	62,12%	47,75%	58,78%
		6	62,41%	51,52%	58,20%	63,86%	47,46%	57,18%
		7	63,43%	46,59%	56,02%	63,57%	45,43%	48,62%
		8	64,01%	47,02%	55,59%	62,41%	44,56%	47,90%
		9	63,28%	47,31%	50,36%	62,41%	44,41%	47,17%
		10	66,04%	45,72%	46,15%	63,43%	46,88%	48,19%

Fonte: Felipe Magami, 2019

Ao se analisar cada estratégia de pré-processamento individualmente, observa-se que, na média, a exclusão das palavras com poucas letras aumentou a taxa de acerto da solução, sugerindo que estas palavras não têm muito importância individualmente quando

são considerados apenas unigramas. Por outro lado, ao se analisar bigramas e trigramas o efeito foi o contrário: os melhores resultados foram obtidos quando nenhuma palavra foi excluída pelo fato de ter poucas letras.

A remoção de *stopwords*, para o presente problema, apresentou resultados iguais ou inferiores aqueles nos quais as *stopwords* não foram removidas. Isto indica que as *stopwords* possuem certa utilidade na classificação do nível de depressão de uma pessoa. De um modo geral, o uso de radicalização apresentou resultados inferiores ao seu não uso. Isto indica que a radicalização pode estar removendo aspectos importantes relacionados a “o que” ou, principalmente, ao “como” uma pessoa está se expressando e estes aspectos podem ser úteis para a classificação do nível de depressão da pessoa. Ao se considerar unigramas, bigramas e trigramas, os melhores resultados foram atingidos por unigramas, seguidos pelos trigramas. Os piores resultados foram obtidos utilizando bigramas.

Para os testes usando um classificador e um seletor de características, o conjunto de postagens de cada pessoa foi representado como um vetor de características binário no qual o valor *true* significa que a pessoa usou um dado termo em sua postagens e o valor *false* significa que ela não usou. Foram produzidos três conjuntos de dados iniciais: um para unigramas, um para bigramas e um para trigramas. Adicionalmente, três conjuntos foram produzidos formados apenas pelas características selecionadas pelo seletor de características.

A tabela 4 apresenta a taxa de acertos do classificador BayesNet para cada um dos seis conjuntos utilizados. Há dois destaques referentes a estes resultados. O primeiro é que o uso do seletor de características produziu uma melhora significativa nos resultados. Isto era esperado, pois o número total de características iniciais (número de diferentes palavras, bigramas ou trigramas) é bastante elevado e isso tende a dificultar o bom desempenho do classificador. Observa-se também que, quando realizada a seleção de características, o uso de unigramas atingiu resultados levemente superiores ao uso de bigramas, os quais também foram levemente superiores ao uso de trigramas.

Tabela 4 – Taxas de acerto da abordagem baseada no uso de classificadores para os quatro níveis de depressão

	Unigrama	Bigrama	Trigrama
Todas as características	57,85%	60,17%	54,36%
Características selecionadas	70,06%	69,62%	69,48%

Fonte: Felipe Magami, 2019

Por fim, destaca-se que a classificação baseada no uso da representação vetorial binária das postagens e usando seleção de características obteve resultados superiores ao uso das medidas baseadas na frequência dos termos. Porém, a diferença entre esses resultados não foi muito alta.

Ao se considerar apenas as pessoas classificadas nos dois níveis extremos de depressão considerados neste trabalho, a amostra contém 536 pessoas. Destas, 35,45% estão classificadas com o menor nível de depressão e 64,55% no maior. Assim, o valor 64,55% será utilizado como baseline do presente estudo de caso.

Devido a utilização de apenas duas classes se torna possível a utilização dos valores baseados em TF*IDF de diferentes formas, conforme apresentado na seção anterior. Desta forma, além das diferentes estratégias de pré-processamento, os três métodos de classificação citados foram utilizados: valor máximo; uso de um limiar para um dos valores; e uso da proporção entre os valores.

A figura 4 apresenta as taxas de acerto do presente estudo de caso, considerando as combinações das diferentes estratégias de pré-processamento e de classificação. Observa-se que o melhor resultado encontrado foi de 83,58% de acerto ao uso de bigramas, sem a exclusão de palavras pequenas, sem a remoção de *stopwords* e com o uso de radicalização. Adicionalmente, a técnica de classificação que obteve este resultado foi o uso do maior valor TF*IDF entre os valores das duas classes consideradas. Há dois destaques relevantes nestes resultados. O primeiro é a considerável diferença da combinação de técnicas de pré-processamento que obteve o melhor resultado neste estudo de caso em relação ao primeiro. O segundo destaque é que o melhor resultado aparece, de certa forma, isolado nesta figura ao se considerar os demais melhores resultados, os quais usam estratégias de pré-processamento diferentes, conforme será discutido a seguir.

A observação de cada uma das estratégias de pré-processamento isoladamente permite observar tendências na mineração e classificação de textos apresentada neste trabalho. Em especial, é possível observar que o melhor resultado obtido não necessariamente seguiu as tendências de melhores resultados ao se analisar as estratégias individualmente.

Ao se considerar a exclusão de palavras pequenas, observa-se que, na média, os melhores resultados são encontrados quando não se exclui nenhuma palavra ou quando se excluem palavras de uma, duas ou três letras. O uso de radicalização, na média, diminuiu as taxas de acerto (em relação a não utilizar radicalização), porém, o melhor resultado geral foi obtido ocorreu utilizando radicalização. A remoção de *stopwords*, assim como no

Figura 4 – Taxas de acerto da abordagem baseada na medida TF*IDF para a classificação em dois níveis de depressão

		Letras Mínima	Unigrama			Bigrama			Trigrama		
			Max	Limiar	Relação	Max	Limiar	Relação	Max	Limiar	Relação
sem radicalização	sem remoção de stopwords	1	81,34%	79,10%	81,90%	82,84%	74,81%	78,36%	79,29%	73,32%	73,88%
		2	81,53%	79,29%	81,90%	81,90%	74,44%	77,43%	75,00%	73,32%	74,44%
		3	81,34%	79,29%	81,53%	82,65%	76,49%	77,05%	70,15%	73,51%	73,51%
		4	82,28%	78,73%	81,90%	80,04%	75,00%	76,12%	69,40%	72,76%	72,76%
		5	81,90%	78,17%	82,09%	77,99%	74,81%	75,56%	55,97%	72,39%	72,57%
		6	82,84%	77,24%	80,78%	72,76%	73,32%	73,69%	47,76%	73,13%	73,13%
		7	81,90%	75,93%	79,48%	62,50%	71,46%	71,46%	41,60%	71,27%	71,27%
		8	79,85%	74,81%	78,17%	56,34%	69,40%	69,40%	37,31%	68,47%	68,47%
		9	79,85%	74,63%	77,61%	49,81%	67,16%	67,54%	36,75%	67,72%	67,72%
		10	78,92%	72,95%	76,68%	49,44%	66,98%	66,98%	36,19%	68,10%	68,10%
	com remoção de stopwords	1	81,90%	78,54%	81,53%	81,72%	76,49%	77,99%	73,51%	74,25%	74,07%
		2	82,65%	78,92%	81,53%	82,09%	76,68%	77,61%	74,07%	73,88%	74,07%
		3	81,53%	78,54%	81,53%	80,41%	76,49%	77,61%	67,16%	74,07%	74,25%
		4	81,72%	78,54%	81,90%	79,48%	74,81%	76,12%	65,49%	72,95%	72,95%
		5	81,16%	77,99%	80,97%	74,44%	74,81%	75,37%	53,54%	72,39%	72,39%
		6	82,09%	76,87%	80,41%	73,13%	73,32%	73,88%	47,95%	73,13%	73,13%
		7	81,72%	75,37%	79,29%	62,50%	71,46%	71,64%	41,60%	71,27%	71,27%
		8	79,29%	73,88%	77,43%	56,16%	69,22%	69,22%	37,31%	68,47%	68,47%
		9	79,29%	74,44%	77,24%	49,81%	67,16%	67,54%	36,75%	67,72%	67,72%
		10	77,61%	72,01%	75,56%	49,44%	66,98%	66,98%	36,19%	68,10%	68,10%
com radicalização	sem remoção de stopwords	1	82,28%	79,85%	82,84%	83,58%	73,88%	78,54%	77,24%	72,76%	74,63%
		2	82,84%	80,22%	82,84%	80,97%	72,39%	75,56%	75,75%	71,83%	72,20%
		3	81,53%	79,48%	82,28%	80,22%	72,95%	75,37%	70,15%	73,13%	73,32%
		4	82,84%	79,10%	81,72%	76,12%	71,83%	72,76%	53,17%	71,46%	71,46%
		5	82,28%	77,61%	81,34%	67,35%	69,22%	69,96%	45,52%	68,47%	68,47%
		6	82,46%	76,49%	80,78%	61,75%	68,10%	69,03%	40,67%	70,71%	70,71%
		7	79,10%	73,13%	76,68%	51,68%	66,60%	66,60%	37,87%	67,16%	67,16%
		8	79,85%	73,32%	75,56%	49,63%	65,49%	66,04%	38,99%	66,04%	66,04%
		9	75,93%	72,01%	73,88%	50,00%	67,91%	68,10%	39,18%	66,04%	66,04%
		10	75,93%	72,76%	75,37%	45,71%	65,67%	65,86%	37,69%	65,11%	65,11%
	com remoção de stopwords	1	82,28%	79,10%	82,65%	82,65%	72,95%	76,12%	73,51%	73,32%	73,69%
		2	82,28%	79,48%	83,02%	81,34%	73,13%	75,56%	73,32%	72,76%	73,13%
		3	81,90%	79,10%	82,09%	80,41%	72,95%	75,37%	70,52%	72,95%	73,13%
		4	82,65%	79,10%	81,72%	76,12%	71,83%	72,76%	53,17%	71,46%	71,46%
		5	82,28%	77,05%	81,16%	67,35%	69,22%	69,96%	45,52%	68,47%	68,47%
		6	82,46%	75,93%	79,85%	61,75%	68,10%	69,03%	40,67%	70,71%	70,71%
		7	78,54%	72,39%	75,75%	51,68%	66,60%	66,60%	37,87%	67,16%	67,16%
		8	78,36%	72,20%	74,44%	49,63%	65,49%	66,04%	38,99%	66,04%	66,04%
		9	74,44%	71,64%	72,57%	50,00%	67,91%	68,10%	39,18%	66,04%	66,04%
		10	73,51%	71,64%	73,88%	45,71%	65,67%	65,86%	37,69%	65,11%	65,11%

Fonte: Felipe Magami, 2019

primeiro estudo de caso, produziu resultados na média um pouco inferiores aos produzidos sem a remoção de *stopwords*. Destaca-se que a diferença média de resultados foi sutil. Em relação ao uso de unigramas, bigramas e trigramas, na média, o uso de unigramas apresentou os melhores resultados, seguidos de bigramas e trigramas. Porém, vale lembrar que o melhor resultado geral foi obtido com a utilização de bigramas. Ao se considerar as três estratégias de classificação testadas, a que obteve os melhores resultados foi o uso do maior valor TF*IDF, seguida do uso da razão entre valores. Na média, os piores resultados foram obtidos utilizando-se um limiar para um destes valores.

A tabela 5 apresenta a taxa de acertos do classificador BayesNet para cada um dos seis conjuntos utilizados. Os mesmos destaques apresentados no estudo de caso anterior são válidos para este estudo: o uso do seletor de características melhorou significativamente os resultados e os resultados utilizando unigramas foram um pouco superiores aos utilizando bigramas e estes foram superiores ao uso de trigramas

Tabela 5 – Taxas de acerto da abordagem baseada no uso de classificadores para os dois níveis extremos de depressão

	Unigrama	Bigrama	Trigrama
Todas as características	86,01%	80,22%	73,88%
Características selecionadas	88,43%	87,31%	80,22%

Fonte: Felipe Magami, 2019

A melhor taxa de acertos obtida por esta abordagem (88,43%) foi significativamente superior à obtida pelo uso de medidas baseadas na frequência das palavras (83,58%). Destaca-se que ambas as abordagens obtiveram resultados bastante superiores ao *baseline* considerado (64,55%).

4.2 Plano de trabalho e cronograma

A tabela 6 mostra o cronograma das atividades propostas começando a partir da data limite para o depósito da qualificação, com duração de um ano. A seguir, são apresentadas as atividades planejadas:

1. Realização da revisão sistemática. Destaca-se que esta atividade já foi finalizada antes da data inicial do cronograma;
2. Realização de revisão bibliográfica complementar à revisão anterior;

3. Extração dos conjuntos de características do conjunto textual, de acordo com os métodos selecionados;
4. Aplicação e parametrização dos classificadores selecionados;
5. Realização dos testes de acordo as estratégias de avaliação e obtenção dos resultados;
6. Realização de testes estatísticos para fins de comparação entre os resultados obtidos na atividade anterior;
7. Análise dos resultados obtidos;
8. Redação da dissertação.

Tabela 6 – Cronograma das atividades propostas

Atividade		2019		2020									
Num.	Descrição	11	12	1	2	3	4	5	6	7	8	9	10
1	Revisão sistemática												
2	Revisão bibliográfica complementar	x	x	x	x	x							
3	Extração dos conjuntos de características	x	x	x	x								
4	Aplicação dos classificadores					x	x						
5	Testes e obtenção dos resultados							x	x	x			
6	Avaliação estatística									x	x	x	
7	Análise dos resultados										x	x	x
8	Redação da dissertação							x	x	x	x	x	x

Fonte: Felipe Magami, 2019

5 Considerações finais

Com este trabalho, pretende-se desenvolver uma técnica que automatize parte do processo de triagem ou (pré-)diagnóstico de pessoas potencialmente depressivas. Espera-se também expandir o conhecimento sobre o processamento de textos oriundos de redes sociais, particularmente em português brasileiro. Mais especificamente, espera-se que nossas contribuições sejam:

- um modelo de detecção de depressão baseado em dados textuais de redes sociais;
- um estudo sobre as técnicas de classificação de depressão utilizando processamento de texto;
- a disponibilização das ferramentas utilizadas para a construção deste modelo.

Este trabalho será limitado para apenas dados textuais de redes sociais em português. Devido à falta de conjuntos de dados públicos dessa natureza, nos limitaremos a utilizar apenas o conjunto de dados descrito anteriormente.

Referências¹

- ABBOT, E. *The Ultimate Guide to Go International on Facebook*. 2019. Disponível em: <https://newsfeed.org/the-ultimate-guide-to-go-international-on-facebook/>. Citado na página 9.
- ABED-ESFAHANI, P.; HOWARD, D.; MASLEJ, M.; PATEL, S.; MANN, V.; GOEGAN, S.; FRENCH, L. Transfer learning for depression: Early detection and severity prediction from social media postings. In: . [S.l.]: CEUR-WS, 2019. v. 2380. Citado na página 22.
- AGGARWAL, C. C. *Machine learning for text*. [S.l.]: Springer, 2018. Citado 2 vezes nas páginas 13 e 14.
- AKINCIGIL, A.; MATTHEWS, E. B. National rates and patterns of depression screening in primary care: results from 2012 and 2013. *Psychiatric services*, Am Psychiatric Assoc, v. 68, n. 7, p. 660–666, 2017. Citado na página 8.
- AL-MOSAIWI, M.; JOHNSTONE, T. In an absolute state: elevated use of absolutist words is a marker specific to anxiety, depression, and suicidal ideation. *Clinical Psychological Science*, v. 6, n. 4, p. 529–542, 2018. Citado na página 9.
- Alghamdi, N. S. Monitoring mental health using smart devices with text analytical tool. In: *2019 6th International Conference on Control, Decision and Information Technologies (CoDIT)*. Paris, França: IEEE, 2019. p. 2046–2051. Citado na página 20.
- ALGHOWINEM, S. From joyous to clinically depressed: Mood detection using multimodal analysis of a person’s appearance and speech. In: . Geneva: [s.n.], 2013. p. 648–653. Citado na página 9.
- ALHANAI, T.; GHASSEMI, M.; GLASS, J. Detecting depression with audio/text sequence modeling of interviews. In: . [S.l.]: International Speech Communication Association, 2018. v. 2018-September, p. 1716–1720. Citado 2 vezes nas páginas 23 e 25.
- ALMEIDA, H.; BRIAND, A.; MEURS, M.-J. Detecting early risk of depression from social media user-generated content. In: . [S.l.]: CEUR-WS, 2017. v. 1866. Citado na página 22.
- American Psychiatric Association. *DSM-5: Manual Diagnóstico e Estatístico de Transtornos Mentais 5ª edição*. [S.l.]: Artmed, 2014. Nenhuma citação no texto.
- ASGARI, M.; SHAFRAN, I.; SHEEBER, L. B. Inferring clinical depression from speech and spoken utterances. In: *2014 IEEE International Workshop on Machine Learning for Signal Processing (MLSP)*. Reims, France: IEEE, 2014. p. 1–5. ISSN 1551-2541. Citado 2 vezes nas páginas 19 e 27.
- BALAGE FILHO, P. P.; PARDO, T. A. S.; ALUÍSIO, S. M. An evaluation of the brazilian portuguese LIWC dictionary for sentiment analysis. In: *Proceedings of the 9th Brazilian Symposium in Information and Human Language Technology*. Fortaleza, Brasil: ACL, 2013. Citado 2 vezes nas páginas 15 e 33.

¹ De acordo com a Associação Brasileira de Normas Técnicas. NBR 6023.

BECK, A.; STEER, R.; BROWN, G. *Manual for the Beck Depression Inventory-II*. San Antonio, EUA, 1996. Citado 2 vezes nas páginas 12 e 27.

BECK, A. T.; WARD, C. H.; MENDELSON, M.; MOCK, J.; ERBAUGH, J. An inventory for measuring depression. *Archives of general psychiatry*, American Medical Association, v. 4, n. 6, p. 561–571, 1961. Citado 3 vezes nas páginas 12, 25 e 27.

BIRJALI, M.; BENI-HSSANE, A.; ERRITALI, M. A method proposed for estimating depressed feeling tendencies of social media users utilizing their data. *Advances in Intelligent Systems and Computing*, Springer Verlag, v. 552, p. 413–420, 2017. Citado 2 vezes nas páginas 24 e 26.

BRADLEY, M. M.; LANG, P. J. *Affective norms for English words (ANEW): Instruction manual and affective ratings*. [S.l.], 1999. Citado na página 28.

BURDISO, S.; ERRECALDE, M.; GÓMEZ, M. Montes-y. A text classification framework for simple and effective early depression detection over social media streams. *Expert Systems with Applications*, Elsevier Ltd, v. 133, p. 182–197, 2019. Citado 3 vezes nas páginas 21, 22 e 29.

BURDISO, S.; ERRECALDE, M.; MONTES-Y-GÓMEZ, M. Unsl at erisk 2019: A unified approach for anorexia, self-harm and depression detection in social media. In: . [S.l.]: CEUR-WS, 2019. v. 2380. Citado 2 vezes nas páginas 21 e 29.

CAREGNATO, M. *Regressão Logística Multinomial: um modelo a partir do comportamento do usuário em rede social para a predição de traços depressivos*. Tese (Doutorado) — Universidade de São Paulo, São Paulo, Brasil, 2018. Citado na página 32.

CHOMUTARE, T.; ÅRSAND, E.; HARTVIGSEN, G. Mining symptoms of severe mood disorders in large internet communities. In: *2015 IEEE 28th International Symposium on Computer-Based Medical Systems*. Sao Carlos, Brazil: IEEE, 2015. p. 214–219. ISSN 2372-9198. Citado na página 19.

CHOUDHURY, M. D.; COUNTS, S.; HORVITZ, E. Social media as a measurement tool of depression in populations. In: *Proceedings of the 5th Annual ACM Web Science Conference*. New York, NY, USA: ACM, 2013. (WebSci '13), p. 47–56. ISBN 978-1-4503-1889-1. Citado 2 vezes nas páginas 20 e 26.

CHOUDHURY, M. D.; COUNTS, S.; HORVITZ, E. J.; HOFF, A. Characterizing and predicting postpartum depression from shared facebook data. In: *Proceedings of the 17th ACM Conference on Computer Supported Cooperative Work & Social Computing*. New York, NY, USA: ACM, 2014. (CSCW '14), p. 626–638. ISBN 978-1-4503-2540-0. Citado 3 vezes nas páginas 20, 26 e 27.

CHOUDHURY, M. D.; GAMON, M.; COUNTS, S.; HORVITZ, E. Predicting depression via social media. In: . Cambridge, MA: AAAI press, 2013. p. 128–137. Citado 5 vezes nas páginas 8, 24, 26, 27 e 33.

CORREIA, J.; RAJ, B.; TRANCOSO, I. Querying depression vlogs. In: *2018 IEEE Spoken Language Technology Workshop (SLT)*. Athens, Greece: IEEE, 2018. p. 987–993. Citado 3 vezes nas páginas 19, 25 e 26.

- CORREIA, J.; RAJ, B.; TRANCOSO, I.; TEIXEIRA, F. Mining multimodal repositories for speech affecting diseases. In: . [S.l.]: International Speech Communication Association, 2018. v. 2018-September, p. 2963–2967. Citado 3 vezes nas páginas 24, 26 e 33.
- DANG, T.; STASAK, B.; HUANG, Z.; JAYAWARDENA, S.; ATCHESON, M.; HAYAT, M.; LE, P.; SETHU, V.; GOECKE, R.; EPPS, J. Investigating word affect features and fusion of probabilistic predictions incorporating uncertainty in avec 2017. In: *Proceedings of the 7th Annual Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2017. (AVEC '17), p. 27–35. ISBN 978-1-4503-5502-5. Citado na página 20.
- DELAHUNTY, F.; WOOD, I.; ARCAN, M. First insights on a passive major depressive disorder prediction system with incorporated conversational chatbot. In: . [S.l.]: CEUR-WS, 2018. v. 2259, p. 327–338. Citado na página 24.
- DESHPANDE, M.; RAO, V. Depression detection using emotion artificial intelligence. In: *2017 International Conference on Intelligent Sustainable Systems (ICISS)*. Palladam, India: IEEE, 2017. p. 858–862. Citado 2 vezes nas páginas 19 e 26.
- EVANS-LACKO, S.; KNAPP, M. Global patterns of workplace productivity for people with depression: absenteeism and presenteeism costs across eight diverse countries. *Social Psychiatry and Psychiatric Epidemiology*, v. 51, n. 11, p. 1525–1537, Nov 2016. ISSN 1433-9285. Disponível em: <https://doi.org/10.1007/s00127-016-1278-4>. Citado na página 8.
- FANG, Y. *et al.* A mental disorder early warning approach by observing depression symptom in social diary. In: *2014 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*. San Diego, CA, USA: IEEE, 2014. p. 2060–2065. ISSN 1062-922X. Citado 2 vezes nas páginas 19 e 26.
- FARÍAS-ANZALDUÁ, A.; MONTES-Y-GÓMEZ, M.; LÓPEZ-MONROY, A. P.; GONZÁLEZ-GURROLA, L. Uach-inaoe participation at erisk2017. In: . [S.l.]: CEUR-WS, 2017. v. 1866. Citado na página 23.
- FATIMA, I.; ABBASI, B.; KHAN, S.; AL-SAEED, M.; AHMAD, H.; MUMTAZ, R. Prediction of postpartum depression using machine learning techniques from social media text. *Expert Systems*, Blackwell Publishing Ltd, v. 36, n. 4, 2019. Citado na página 24.
- FUNEZ, D.; UCELAY, M. G.; VILLEGAS, M.; BURDISSO, S.; CAGNINA, L.; MONTES-Y-GÓMEZ, M.; ERRECALDE, M. Unsl's participation at erisk 2018 lab. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 22.
- GONG, Y.; POELLABAUER, C. Topic modeling based multi-modal depression detection. In: *Proceedings of the 7th Annual Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2017. (AVEC '17), p. 69–76. ISBN 978-1-4503-5502-5. Citado na página 21.
- GRATCH, J.; ARTSTEIN, R.; LUCAS, G.; STRATOU, G.; SCHERER, S.; NAZARIAN, A.; WOOD, R.; BOBERG, J.; DEVAULT, D.; MARSELLA, S.; TRAUM, D.; RIZZO, S.; MORENCY, L.-P. The distress analysis interview corpus of human and computer interviews. In: *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC-2014)*. Reykjavik, Iceland: European Languages Resources Association (ELRA), 2014. p. 3123–3128. Citado 6 vezes nas páginas 19, 20, 21, 23, 24 e 25.

GUPTA, R.; MALANDRAKIS, N.; XIAO, B.; GUHA, T.; SEGBROECK, M. V.; BLACK, M.; POTAMIANOS, A.; NARAYANAN, S. Multimodal prediction of affective dimensions and depression in human-computer interactions. In: *Proceedings of the 4th International Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2014. (AVEC '14), p. 33–40. ISBN 978-1-4503-3119-7. Citado na página 20.

HALL, M. *Correlation-Based Feature Selection for Machine Learning*. Tese (Doutorado) — University of Waikato, 1999. Citado na página 36.

HARTMANN, N. *et al.* Portuguese word embeddings: Evaluating on word analogies and natural language tasks. In: *Proceedings of the 11th Brazilian Symposium in Information and Human Language Technology*. Uberlândia, Brasil: ACL, 2017. p. 122–131. Citado 2 vezes nas páginas 16 e 33.

HIRAGA, M. Predicting depression for japanese blog text. In: . [S.l.]: Association for Computational Linguistics (ACL), 2017. p. 107–113. Citado na página 23.

HOTH, A.; NÜRNBERGER, A.; PAASS, G. A brief survey of text mining. In: CITESEER. *Ldv Forum*. [S.l.], 2005. v. 20, n. 1, p. 19–62. Citado na página 14.

JARROLD, W.; PEINTNER, B.; YEH, E.; KRASNOW, R.; JAVITZ, H.; SWAN, G. Language analytics for assessing brain health: Cognitive impairment, depression and pre-symptomatic alzheimer's disease. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, v. 6334 LNAI, p. 299–307, 2010. Citado na página 21.

JIANG, H.; HU, B.; LIU, Z.; WANG, G.; ZHANG, L.; LI, X.; KANG, H. Detecting depression using an ensemble logistic regression model based on multiple speech features. *Computational and mathematical methods in medicine*, NLM (Medline), v. 2018, p. 6508319, 2018. Citado na página 9.

KANG, K.; YOON, C.; KIM, E. Y. Identifying depressive users in Twitter using multimodal analysis. In: *2016 International Conference on Big Data and Smart Computing (BigComp)*. Hong Kong, China: IEEE, 2016. p. 231–238. ISSN 2375-9356. Citado 2 vezes nas páginas 19 e 26.

KARMEN, C.; HSIUNG, R.; WETTER, T. Screening internet forum participants for depression symptoms by assembling and enhancing multiple nlp methods. *Computer Methods and Programs in Biomedicine*, Elsevier Ireland Ltd, v. 120, n. 1, p. 27–36, 2015. Citado 4 vezes nas páginas 19, 22, 28 e 29.

KATCHAPAKIRIN, K. *et al.* Facebook social media for depression detection in the Thai community. In: *2018 15th International Joint Conference on Computer Science and Software Engineering (JCSSE)*. Nakhonpathom, Thailand: IEEE, 2018. p. 1–6. Citado 2 vezes nas páginas 19 e 26.

KISS, G.; TULICS, M.; SZTAHÓ, D.; ESPOSITO, A.; VICSI, K. Language independent detection possibilities of depression by speech. *Smart Innovation, Systems and Technologies*, Springer Science and Business Media Deutschland GmbH, v. 48, p. 103–114, 2016. Citado na página 9.

KITCHENHAM, B. Procedures for performing systematic reviews. *Keele, UK, Keele University*, v. 33, n. 2004, p. 1–26, 2004. Citado na página 17.

KORB, K. B.; NICHOLSON, A. E. *Bayesian Artificial Intelligence, Second Edition*. 2nd. ed. Boca Raton, FL, USA: CRC Press, Inc., 2010. ISBN 1439815917, 9781439815915. Citado na página 36.

KROENKE, K.; SPITZER, R. L. The phq-9: a new depression diagnostic and severity measure. *Psychiatric annals*, Slack Incorporated, v. 32, n. 9, p. 509–515, 2002. Citado na página 27.

KROENKE, K.; STRINE, T. W.; SPITZER, R. L.; WILLIAMS, J. B.; BERRY, J. T.; MOKDAD, A. H. The phq-8 as a measure of current depression in the general population. *Journal of affective disorders*, Elsevier, v. 114, n. 1-3, p. 163–173, 2009. Citado na página 26.

LAM, G.; DONGYAN, H.; LIN, W. Context-aware deep learning for multi-modal depression detection. In: *ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Brighton, UK: IEEE, 2019. p. 3946–3950. ISSN 2379-190X. Citado 2 vezes nas páginas 20 e 25.

LE, Q.; MIKOLOV, T. Distributed representations of sentences and documents. In: *Proceedings of the 31st International Conference on International Conference on Machine Learning - Volume 32*. [S.l.]: JMLR.org, 2014. (ICML'14), p. II–1188–II–1196. Citado 2 vezes nas páginas 16 e 29.

LOPEZ-OTERO, P.; DOCIO-FERNANDEZ, L.; ABAD, A.; GARCIA-MATEO, C. Depression detection using automatic transcriptions of de-identified speech. In: . [S.l.]: International Speech Communication Association, 2017. v. 2017-August, p. 3157–3161. Citado 2 vezes nas páginas 23 e 28.

LOSADA, D.; CRESTANI, F. A test collection for research on depression and language use. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer Verlag, v. 9822 LNCS, p. 28–39, 2016. Citado 9 vezes nas páginas 19, 20, 21, 22, 23, 24, 25, 26 e 27.

LOSADA, D. E.; CRESTANI, F.; PARAPAR, J. Clef 2017 erisk overview: Early risk prediction on the internet: Experimental foundations. In: *CLEF (Working Notes)*. [S.l.: s.n.], 2017. Citado na página 25.

LOSADA, D. E.; CRESTANI, F.; PARAPAR, J. Overview of erisk: early risk prediction on the internet. In: SPRINGER. *International Conference of the Cross-Language Evaluation Forum for European Languages*. [S.l.], 2018. p. 343–361. Citado na página 25.

LOSADA, D. E.; CRESTANI, F.; PARAPAR, J. Overview of erisk 2019: Early risk prediction on the internet. In: SPRINGER. *International Conference of the Cross-Language Evaluation Forum for European Languages*. [S.l.], 2019. p. 340–357. Citado 5 vezes nas páginas 21, 22, 23, 24 e 25.

MAURER, D. M.; RAYMOND, T. J.; DAVIS, B. N. Depression: Screening and diagnosis. *American family physician*, v. 98, n. 8, p. 508–515, 2018. Citado na página 12.

MIKOLOV, T. *et al.* Efficient estimation of word representations in vector space. In: *1st International Conference on Learning Representations*. Scottsdale, EUA: Grimm Brothers Co., 2013. Citado 2 vezes nas páginas 15 e 28.

MIKOLOV, T.; SUTSKEVER, I.; CHEN, K.; CORRADO, G.; DEAN, J. Distributed representations of words and phrases and their compositionality. In: *Proceedings of the 26th International Conference on Neural Information Processing Systems - Volume 2*. USA: Curran Associates Inc., 2013. (NIPS'13), p. 3111–3119. Disponível em: <http://dl.acm.org/citation.cfm?id=2999792.2999959>. Nenhuma citação no texto.

MORALES, M.; SCHERER, S.; LEVITAN, R. Openmm: An open-source multimodal feature extraction tool. In: . [S.l.]: International Speech Communication Association, 2017. v. 2017-August, p. 3354–3358. Citado na página 24.

MORALES, M. R.; LEVITAN, R. Speech vs. text: A comparative analysis of features for depression detection systems. In: *2016 IEEE Spoken Language Technology Workshop (SLT)*. San Diego, USA: IEEE, 2016. p. 136–143. Citado na página 19.

NAKAMURA, T.; KUBO, K.; USUDA, Y.; ARAMAKI, E. Defining patients with depressive disorder by using textual information. In: . Palo Alto, CA: AI Access Foundation, 2014. SS-14-01, p. 39–44. Citado 2 vezes nas páginas 23 e 26.

NATIONAL INSTITUTE OF MENTAL HEALTH. Depression. *Government Printing Office*, Bethesda, EUA, 2015. Citado na página 8.

NGUYEN, T. *et al.* Affective and content analysis of online depression communities. *IEEE Transactions on Affective Computing*, IEEE, v. 5, n. 3, p. 217–226, July 2014. ISSN 1949-3045. Citado 3 vezes nas páginas 19, 26 e 28.

NGUYEN, T.; O'DEA, B.; LARSEN, M.; PHUNG, D.; VENKATESH, S.; CHRISTENSEN, H. Differentiating sub-groups of online depression-related communities using textual cues. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer Verlag, v. 9419, p. 216–224, 2015. Citado 3 vezes nas páginas 24, 26 e 28.

NGUYEN, T.; O'DEA, B.; LARSEN, M.; PHUNG, D.; VENKATESH, S.; CHRISTENSEN, H. Using linguistic and topic analysis to classify sub-groups of online depression communities. *Multimedia Tools and Applications*, Springer New York LLC, v. 76, n. 8, p. 10653–10676, 2017. Citado 3 vezes nas páginas 24, 26 e 28.

NISBET, R.; ELDER, J.; MINER, G. *Handbook of statistical analysis and data mining applications*. [S.l.]: Academic Press, 2009. Citado na página 13.

ORGANIZAÇÃO MUNDIAL DE SAÚDE. *Depression and other common mental disorders: global health estimates*. Genebra, Suíça: [s.n.], 2017. Citado na página 8.

ORHAN, Z.; MERCAN, M.; GÖKGÖL, M. A new digital mental health system infrastructure for diagnosis of psychiatric disorders and patient follow-up by text analysis in turkish. In: . [S.l.]: Springer Verlag, 2020. v. 73, p. 395–402. Citado 2 vezes nas páginas 21 e 27.

ORTEGA-MENDOZA, R.; LÓPEZ-MONROY, A.; FRANCO-ARCEGA, A.; MONTES-Y-GÓMEZ, M. Peimex at erisk2018: Emphasizing personal information for depression and anorexia detection. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 22.

OYONG, I.; UTAMI, E.; LUTHFI, E. T. Natural language processing and lexical approach for depression symptoms screening of Indonesian Twitter user. In: *2018 10th International Conference on Information Technology and Electrical Engineering (ICITEE)*. Kuta, Indonesia: IEEE, 2018. p. 359–364. Citado 3 vezes nas páginas 19, 26 e 28.

PAMPOUCHIDOU, A.; SIMANTIRAKI, O.; FAZLOLLAHI, A.; PEDIADITIS, M.; MANOUSOS, D.; RONIOTIS, A.; GIANNAKAKIS, G.; MERIAUDEAU, F.; SIMOS, P.; MARIAS, K.; YANG, F.; TSIKNAKIS, M. Depression assessment by fusing high and low level features from audio, video, and text. In: *Proceedings of the 6th International Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2016. (AVEC '16), p. 27–34. ISBN 978-1-4503-4516-3. Citado na página 20.

PAUL, S.; KALYANI, J.; BASU, T. Early detection of signs of anorexia and depression over social media using effective machine learning frameworks. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 24.

PENG, Z.; HU, Q.; DANG, J. Multi-kernel svm based depression recognition using social media data. *International Journal of Machine Learning and Cybernetics*, Springer Verlag, v. 10, n. 1, p. 43–57, 2019. Citado na página 22.

PENNEBAKER, J. W.; MEHL, M. R.; NIEDERHOFFER, K. G. Psychological aspects of natural language use: our words, our selves. *Annual review of psychology*, Palo Alto, EUA, v. 54, n. 1, p. 547–577, 2003. Citado 2 vezes nas páginas 9 e 32.

PENNINGTON, J.; SOCHER, R.; MANNING, C. D. Glove: Global vectors for word representation. In: *Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Catar: ACL, 2014. p. 1532–1543. Citado na página 28.

PIRINA, I.; ÇÖLTEKIN, Identifying depression on reddit: The effect of training data. In: . [S.l.: s.n.], 2018. p. 9–12. Citado na página 19.

POWELL, V. B.; ABREU, N.; OLIVEIRA, I. R. d.; SUDAK, D. Terapia cognitivo-comportamental da depressão. *Brazilian Journal of Psychiatry*, scielo, v. 30, p. s73 – s80, 10 2008. ISSN 1516-4446. Disponível em: http://www.scielo.br/scielo.php?script=sci_arttext&pid=S1516-44462008000600004&nrm=iso. Citado na página 12.

RAGHEB, W.; MOULAH, B.; AZÉ, J.; BRINGAY, S.; SERVAJEAN, M. Temporal mood variation: At the clef erisk-2018 tasks for early risk detection on the internet. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 23.

RAMIANDRISOA, F.; MOTHE, J.; BENAMARA, F.; MORICEAU, V. Irit at e-risk 2018. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado 2 vezes nas páginas 21 e 28.

RAMÍREZ-CIFUENTES, D.; FREIRE, A. Upf's participation at the clef erisk 2018: Early risk prediction on the internet. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 24.

RATHNER, E.-M.; DJAMALI, J.; TERHORST, Y.; SCHULLER, B.; CUMMINS, N.; SALAMON, G.; HUNGER-SCHOPPE, C.; BAUMEISTER, H. How did you like 2017? detection of language markers of depression and narcissism in personal narratives. In: . [S.l.]: International Speech Communication Association, 2018. v. 2018-September, p. 3388–3392. Citado na página 21.

RAZZOUK, D. Capital mental, custos indiretos e saúde mental. In: D LIMA M, Q. C. R. (Ed.). *Saúde mental e trabalho*. São Paulo, Brasil: Conselho Regional de Medicina do Estado de São Paulo, 2016. cap. 3, p. 63–71. Citado na página 8.

RAZZOUK, D. Por que o Brasil deveria priorizar o tratamento da depressão na alocação dos recursos da Saúde? *Epidemiologia e Serviços de Saúde*, SciELO Public Health, v. 25, p. 845–848, 2016. Citado na página 29.

RESNIK, P.; GARRON, A.; RESNIK, R. Using topic modeling to improve prediction of neuroticism and depression in college students. In: . [S.l.]: Association for Computational Linguistics (ACL), 2013. p. 1348–1353. Citado 2 vezes nas páginas 21 e 28.

RIJEN, P. V.; TEODORO, D.; NADERI, N.; MOTTIN, L.; KNAFOU, J.; JEFFRYES, M.; RUCH, P. A data-driven approach for measuring the severity of the signs of depression using reddit posts. In: . [S.l.]: CEUR-WS, 2019. v. 2380. Citado na página 23.

RINGEVAL, F.; SCHULLER, B.; VALSTAR, M.; GRATCH, J.; COWIE, R.; SCHERER, S.; MOZGAI, S.; CUMMINS, N.; SCHMITT, M.; PANTIC, M. Avec 2017: Real-life depression, and affect recognition workshop and challenge. In: *Proceedings of the 7th Annual Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2017. (AVEC '17), p. 3–9. ISBN 978-1-4503-5502-5. Citado na página 25.

ROSENMAN, R. H.; FRIEDMAN, M.; STRAUS, R.; WURM, M.; KOSITCHEK, R.; HAHN, W.; WERTHESEN, N. T. A Predictive Study of Coronary Heart Disease: The Western Collaborative Group Study. *JAMA*, v. 189, n. 1, p. 15–22, 07 1964. ISSN 0098-7484. Citado na página 21.

RUDE, S.; GORTNER, E.-M.; PENNEBAKER, J. Language use of depressed and depression-vulnerable college students. *Cognition & Emotion*, v. 18, p. 1121–1133, 2004. Citado 4 vezes nas páginas 9, 21, 28 e 32.

SADEQUE, F.; XU, D.; BETHARD, S. Uarizona at the clef erisk 2017 pilot task: Linear and recurrent models for early depression detection. In: . [S.l.]: CEUR-WS, 2017. v. 1866. Citado 2 vezes nas páginas 21 e 23.

SADEQUE, F.; XU, D.; BETHARD, S. Measuring the latency of depression detection in social media. In: *Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining*. New York, NY, USA: ACM, 2018. (WSDM '18), p. 495–503. ISBN 978-1-4503-5581-0. Citado na página 20.

SAMAREH, A.; JIN, Y.; WANG, Z.; CHANG, X.; HUANG, S. Detect depression from communication: how computer vision, signal processing, and sentiment analysis join forces. *IJSE Transactions on Healthcare Systems Engineering*, Taylor and Francis Inc., v. 8, n. 3, p. 196–208, 2018. Citado na página 23.

SMIRNOVA, D.; CUMMING, P.; SLOEVA, E.; KUVSHINOVA, N.; ROMANOV, D.; NOSACHEV, G. Language patterns discriminate mild depression from normal sadness and euthymic state. *Frontiers in Psychiatry*, v. 9, p. 105, 04 2018. Citado 2 vezes nas páginas 9 e 32.

STANKEVICH, M.; ISAKOV, V.; DEYATKIN, D.; SMIRNOV, I. Feature engineering for depression detection in social media. In: . [S.l.]: SciTePress, 2018. v. 2018-January, p. 426–431. Citado na página 23.

STEPANOV, E. A. *et al.* Depression severity estimation from multiple modalities. In: *2018 IEEE 20th International Conference on e-Health Networking, Applications and Services (Healthcom)*. Ostrava, Czech Republic: IEEE, 2018. p. 1–6. Citado 2 vezes nas páginas 19 e 28.

SUGANDHI, R.; MAHAJAN, A. A semantic network approach to affect analysis: A case study on depression. In: . [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2017. v. 2017-January, p. 255–266. Citado na página 23.

SUN, B.; ZHANG, Y.; HE, J.; YU, L.; XU, Q.; LI, D.; WANG, Z. A random forest regression method with selected-text feature for depression assessment. In: *Proceedings of the 7th Annual Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2017. (AVEC '17), p. 61–68. ISBN 978-1-4503-5502-5. Citado 2 vezes nas páginas 20 e 25.

TADESSE, M. M. *et al.* Detection of depression-related posts in reddit social media forum. *IEEE Access*, IEEE, v. 7, p. 44883–44893, 2019. ISSN 2169-3536. Citado 2 vezes nas páginas 19 e 28.

TAN, A. H. *et al.* Text mining: The state of the art and the challenges. In: *Proceedings of the PAKDD 1999 Workshop on Knowledge Discovery from Advanced Databases*. Beijing, China: [s.n.], 1999. v. 8, p. 65–70. Citado na página 9.

TAUSCZIK, Y. R.; PENNEBAKER, J. W. The psychological meaning of words: LIWC and computerized text analysis methods. *Journal of Language and Social Psychology*, v. 29, n. 1, p. 24–54, 2010. Citado 2 vezes nas páginas 15 e 28.

TENG, C. T.; HUMES, E. d. C.; DEMETRIO, F. N. Depressão e comorbidades clínicas. *Archives of Clinical Psychiatry (São Paulo)*, scielo, v. 32, p. 149 – 159, 06 2005. Citado na página 8.

Tlachac, M.; Toto, E.; Rundensteiner, E. You're making me depressed: Leveraging texts from contact subsets to predict depression. In: *2019 IEEE EMBS International Conference on Biomedical Health Informatics (BHI)*. Chicago, EUA: IEEE, 2019. p. 1–4. Citado 2 vezes nas páginas 20 e 27.

TRANCOSO, I.; CORREIA, J.; TEIXEIRA, F.; RAJ, B.; ABAD, A. Speech analytics for medical applications. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer Verlag, v. 11107 LNAI, p. 26–37, 2018. Citado 3 vezes nas páginas 19, 24 e 26.

TRIFAN, A.; OLIVEIRA, J. Bioinfo@uavrr at erisk 2019: Delving into social media texts for the early detection of mental and food disorders. In: . [S.l.]: CEUR-WS, 2019. v. 2380. Citado na página 24.

TRIFU, R.; NEMES, B.; BODEA-HAȚEGAN, C.; COZMAN, D. Linguistic indicators of language in major depressive disorder (mdd). an evidence based research. *Journal of Evidence-Based Psychotherapies*, v. 17, p. 105–128, 03 2017. Citado na página 28.

TROTZEK, M.; KOITKA, S.; FRIEDRICH, C. Linguistic metadata augmented classifiers at the clef 2017 task for early detection of depression: Fhdo biomedical computer science group (bcsbg). In: . [S.l.]: CEUR-WS, 2017. v. 1866. Citado na página 22.

TROTZEK, M.; KOITKA, S.; FRIEDRICH, C. Word embeddings and linguistic metadata at the clef 2018 tasks for early detection of depression and anorexia. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 23.

TROTZEK, M.; KOITKA, S.; FRIEDRICH, C. M. Utilizing neural networks and linguistic metadata for early detection of depression indications in text sequences. *IEEE Transactions on Knowledge and Data Engineering*, IEEE, p. 1–1, 2019. ISSN 1041-4347. Citado 3 vezes nas páginas 8, 19 e 33.

TUNG, C.; LU, W. Analyzing depression tendency of web posts using an event-driven depression tendency warning model. *Artificial Intelligence in Medicine*, Elsevier, v. 66, p. 53–62, 2016. Citado na página 24.

VALSTAR, M.; GRATCH, J.; SCHULLER, B.; RINGEVAL, F.; LALANNE, D.; TORRES, M. T.; SCHERER, S.; STRATOU, G.; COWIE, R.; PANTIC, M. Avec 2016: Depression, mood, and emotion recognition workshop and challenge. In: ACM. *Proceedings of the 6th international workshop on audio/visual emotion challenge*. [S.l.], 2016. p. 3–10. Citado 2 vezes nas páginas 19 e 25.

VALSTAR, M.; SCHULLER, B.; SMITH, K.; ALMAEV, T.; EYBEN, F.; KRAJEWSKI, J.; COWIE, R.; PANTIC, M. Avec 2014: 3d dimensional affect and depression recognition challenge. In: *Proceedings of the 4th International Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2014. (AVEC '14), p. 3–10. ISBN 978-1-4503-3119-7. Citado 4 vezes nas páginas 19, 20, 24 e 25.

VILLATORO-TELLO, E.; ROSA, G. Ramírez-De-la; JIMÉNEZ-SALAZAR, H. Uam's participation at clef erisk 2017 task: Towards modelling depressed bloggers. In: . [S.l.]: CEUR-WS, 2017. v. 1866. Citado na página 21.

VILLEGAS, M. P.; FUNEZ, D.; UCELAY, M. J. G.; CAGNINA, L.; ERRECALDE, M. Lidic - unsl's participation at erisk 2017: Pilot task on early detection of depression: Notebook for erisk at clef 2017. In: . [S.l.]: CEUR-WS, 2017. v. 1866. Citado na página 22.

WANG, Y.-T.; HUANG, H.-H.; CHEN, H.-H. A neural network approach to early risk detection of depression and anorexia on social media text. In: . [S.l.]: CEUR-WS, 2018. v. 2125. Citado na página 22.

WARRINER, A. B.; KUPERMAN, V.; BRYSSBAERT, M. Norms of valence, arousal, and dominance for 13,915 english lemmas. *Behavior Research Methods*, v. 45, n. 4, p. 1191–1207, Dec 2013. ISSN 1554-3528. Citado na página 19.

WEISS, S. M.; INDURKHYA, N.; ZHANG, T. *Fundamentals of predictive text mining*. [S.l.]: Springer, 2015. Citado 3 vezes nas páginas 9, 13 e 15.

WILLIAMSON, J. R.; GODOY, E.; CHA, M.; SCHWARZENTRUBER, A.; KHORRAMI, P.; GWON, Y.; KUNG, H.-T.; DAGLI, C.; QUATIERI, T. F. Detecting depression using vocal, facial and semantic communication cues. In: *Proceedings of the 6th International Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2016. (AVEC '16), p. 11–18. ISBN 978-1-4503-4516-3. Citado na página 20.

- WU, P.; KOH, J.; CHEN, A. L. P. Event detection for exploring emotional upheavals of depressive people. In: *Proceedings of the 34th ACM/SIGAPP Symposium on Applied Computing*. New York, NY, USA: ACM, 2019. (SAC '19), p. 2086–2095. ISBN 978-1-4503-5933-7. Citado 2 vezes nas páginas 20 e 26.
- YANG, L.; JIANG, D.; SAHLI, H. Integrating deep and shallow models for multi-modal depression analysis — hybrid architectures. *IEEE Transactions on Affective Computing*, IEEE, p. 1–1, 2018. ISSN 1949-3045. Citado 2 vezes nas páginas 19 e 28.
- YANG, L.; JIANG, D.; XIA, X.; PEI, E.; OVENEKE, M. C.; SAHLI, H. Multimodal measurement of depression using deep learning models. In: *Proceedings of the 7th Annual Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2017. (AVEC '17), p. 53–59. ISBN 978-1-4503-5502-5. Citado na página 20.
- YANG, L.; SAHLI, H.; XIA, X.; PEI, E.; OVENEKE, M. C.; JIANG, D. Hybrid depression classification and estimation from audio video and text information. In: *Proceedings of the 7th Annual Workshop on Audio/Visual Emotion Challenge*. New York, NY, USA: ACM, 2017. (AVEC '17), p. 45–51. ISBN 978-1-4503-5502-5. Citado 2 vezes nas páginas 20 e 25.
- YANG, T. *et al.* Detection of mood disorder using speech emotion profiles and lstm. In: *2016 10th International Symposium on Chinese Spoken Language Processing (ISCSLP)*. Tianjin, China: IEEE, 2016. p. 1–5. Citado na página 9.
- YAZDAVAR, A. H.; AL-OLIMAT, H. S.; EBRAHIMI, M.; BAJAJ, G.; BANERJEE, T.; THIRUNARAYAN, K.; PATHAK, J.; SHETH, A. Semi-supervised approach to monitoring clinical depressive symptoms in social media. In: *Proceedings of the 2017 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining 2017*. New York, NY, USA: ACM, 2017. (ASONAM '17), p. 1191–1198. ISBN 978-1-4503-4993-2. Citado 3 vezes nas páginas 20, 26 e 28.
- YUSOF, N.; LIN, C.; GUERIN, F. Assessing the effectiveness of affective lexicons for depression classification. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer Verlag, v. 10859 LNCS, p. 65–69, 2018. Citado 2 vezes nas páginas 23 e 26.
- ZHAO, X.; LIN, S.; HUANG, Z. Text classification of micro-blog's “tree hole” based on convolutional neural network. In: . [S.l.]: Association for Computing Machinery, 2018. Citado na página 22.
- ZIEMER, K.; KORKMAZ, G. Using text to predict psychological and physical health: A comparison of human raters and computerized text analysis. *Computers in Human Behavior*, Elsevier Ltd, v. 76, p. 122–127, 2017. Citado na página 22.

Anexo A – Questionário BDI-II

Instruções: Este questionário consiste em 21 grupos de afirmações. Por favor, leia cada uma delas cuidadosamente. Depois escolha uma frase de cada grupo (questão), que melhor descreve o modo como você tem se sentido nas **duas últimas semanas, incluindo o dia de hoje**. Clique na alternativa de número (0, 1, 2 ou 3), correspondente a afirmação escolhida em cada grupo. Se mais de uma afirmação em um grupo lhe parecer igualmente apropriada, escolha a de número mais alto neste grupo. Marque apenas uma afirmação por grupo, incluindo o item 16 (alteração no padrão de sono) e o item 18 (alterações de apetite).

1. Tristeza

- 0 Não me sinto triste.
- 1 Eu me sinto triste grande parte do tempo.
- 2 Estou triste o tempo todo.
- 3 Estou tão triste ou tão infeliz que não consigo suportar.

2. Pessimismo

- 0 Não estou desanimado(a) a respeito do meu futuro.
- 1 Eu me sinto mais desanimado(a) a respeito do meu futuro do que de costume.
- 2 Não espero que as coisas deem certo pra mim.
- 3 Sinto que não há esperança quanto ao meu futuro. Acho que só vai piorar.

3. Fracasso passado

- 0 Não me sinto um(a) fracassado(a).
- 1 Tenho fracassado mais do que deveria.
- 2 Quando penso no passado vejo muitos fracassos.
- 3 Sinto que como pessoa sou um fracasso total.

4. Perda de prazer

- 0 Continuo sentindo o mesmo prazer que sentia com as coisas de que eu gosto.
- 1 Não sinto tanto prazer com as coisas como costumava sentir.
- 2 Tenho muito pouco prazer nas coisas que eu costumava gostar.
- 3 Não tenho mais nenhum prazer nas coisas que eu costumava gostar.

5. Sentimento de culpa

- 0 Não me sinto particularmente culpado(a).
- 1 Eu me sinto culpado(a) a respeito de várias coisas que fiz e/ou que deveria ter feito.

- 2 Eu me sinto culpado(a) a maior parte do tempo.
- 3 Eu me sinto culpado(a) o tempo todo.

6. Sentimento de punição

- 0 Não sinto que estou sendo punido(a).
- 1 Sinto que posso ser punido(a).
- 2 Eu acho que serei punido(a).
- 3 Sinto que estou sendo punido(a).

7. Auto-estima

- 0 Eu me sinto como sempre me senti em relação a mim mesmo(a).
- 1 Perdi a confiança em mim mesmo(a).
- 2 Estou desapontado(a) comigo mesmo(a).
- 3 Não gosto de mim.

8. Autocrítica

- 0 Não me critico nem me culpo mais do que o habitual.
- 1 Estou sendo mais crítico(a) comigo mesmo(a) do que costumava ser.
- 2 Eu me critico por todos os meus erros.
- 3 Eu me culpo por tudo de ruim que acontece.

9. Pensamentos ou desejos suicidas

- 0 Não tenho nenhum pensamento de me matar.
- 1 Tenho pensamentos de me matar, mas não levaria isso adiante.
- 2 Gostaria de me matar.
- 3 Eu me mataria de tivesse oportunidade.

10. Choro

- 0 Não choro mais do que chorava antes.
- 1 Choro mais agora do que costumava chorar.
- 2 Choro por qualquer coisinha.
- 3 Sinto vontade de chorar, mas não consigo.

11. Agitação

- 0 Não me sinto mais inquieto(a) ou agitado(a) do que me sentia antes.
- 1 Eu me sinto mais inquieto(a) ou agitado(a) do que me sentia antes.
- 2 Eu me sinto tão inquieto(a) ou agitado(a) que é difícil ficar parado(a).
- 3 Estou tão inquieto(a) ou agitado(a) que tenho que estar sempre me mexendo ou fazendo alguma coisa.

12. Perda de interesse

- 0 Não perdi o interesse por outras pessoas ou por minhas atividades.

- 1 Estou menos interessado pelas outras pessoas ou coisas do que costumava estar.
- 2 Perdi quase todo o interesse por outras pessoas ou coisas.
- 3 É difícil me interessar por alguma coisa.

13. Indecisão

- 0 Tomo minhas decisões tão bem quanto antes.
- 1 Acho mais difícil tomar decisões agora do que antes.
- 2 Tenho muito mais dificuldade em tomar decisões agora do que antes.
- 3 Tenho dificuldade para tomar qualquer decisão.

14. Desvalorização

- 0 Não me sinto sem valor.
- 1 Não me considero hoje tão útil ou não me valorizo como antes.
- 2 Eu me sinto com menos valor quando me comparo com outras pessoas.
- 3 Eu me sinto completamente sem valor.

15. Falta de energia

- 0 Tenho tanta energia hoje como sempre tive.
- 1 Tenho menos energia do que costumava ter.
- 2 Não tenho energia suficiente para fazer muita coisa.
- 3 Não tenho energia suficiente para nada.

16. Alteração no padrão de sono

- 0 Não percebi nenhuma mudança no meu sono.
- 1a Durmo um pouco mais do que o habitual.
- 1b Durmo um pouco menos do que o habitual.
- 2a Durmo muito mais do que o habitual.
- 2b Durmo muito menos do que o habitual.
- 3a Durmo a maior parte do dia.
- 3b Acordo 1 ou 2 horas mais cedo e não consigo voltar a dormir.

17. Irritabilidade

- 0 Não estou mais irritado(a) do que o habitual.
- 1 Estou mais irritado(a) do que o habitual.
- 2 Estou muito mais irritado(a) do que o habitual.
- 3 Fico irritado(a) o tempo todo.

18. Alteração de apetite

- 0 Não percebi nenhuma mudança no meu apetite.
- 1a Meu apetite está um pouco menor do que o habitual.
- 1b Meu apetite está um pouco maior do que o habitual.
- 2a Meu apetite está muito menor do que antes.
- 2b Meu apetite está muito maior do que antes.

- 3a Não tenho nenhum apetite.
- 3b Quero comer o tempo todo.

19. Dificuldade de concentração

- 0 Posso me concentrar tão bem quanto antes.
- 1 Não posso me concentrar tão bem quanto habitualmente.
- 2 É muito difícil manter a concentração em alguma coisa por muito tempo.
- 3 Eu acho que não consigo me concentrar em nada.

20. Cansaço ou fadiga

- 0 Não estou mais cansado(a) ou fadigado(a) do que o habitual.
- 1 Fico cansado(a) ou fadigado(a) mais facilmente do que o habitual.
- 2 Eu me sinto muito cansado(a) ou fadigado(a) para fazer muitas das coisas que costumava fazer.
- 3 Eu me sinto muito cansado(a) ou fadigado(a) para fazer a maioria das coisas que costumava fazer.

21. Perda de interesse por sexo

- 0 Não notei qualquer mudança recente no meu interesse por sexo.
- 1 Estou menos interessado(a) em sexo do que costumava estar.
- 2 Estou muito menos interessado(a) em sexo agora.
- 3 Perdi completamente o interesse por sexo.

Muito obrigada pela sua cooperação!

Anexo B – Trâmite do projeto de pesquisa no Comitê de Ética

Detalhes da tramitação do projeto de pesquisa e seu parecer julgado pelo Comitê de Ética em Pesquisa com Seres Humanos do Instituto de Psicologia da USP (CEPH-IPUSP).

A figura 5 exibe todo o histórico da tramitação do projeto no comitê de ética, desde a sua entrada até a aprovação no dia 12 de maio de 2017.

Figura 5 – Histórico da tramitação do projeto de pesquisa

HISTÓRICO DE TRÂMITES							
Apreciação	Data/Hora	Tipo Trâmite	Versão	Perfil	Origem	Destino	Informações
N1	12/05/2017 09:02:36	Aceitação do PP	1	Secretária	PESQUISADOR	USP- Instituto de Psicologia da Universidade de São Paulo	
N1	11/05/2017 19:47:17	Notificação enviada	1	Pesquisador	PESQUISADOR	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	18/04/2017 11:16:19	Parecer liberado	1	Coordenador	USP- Instituto de Psicologia da Universidade de São Paulo	PESQUISADOR	
PO	17/04/2017 15:10:01	Parecer do colegiado emitido	1	Coordenador	USP- Instituto de Psicologia da Universidade de São Paulo	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	09/04/2017 18:20:04	Parecer do relator emitido	1	Coordenador	USP- Instituto de Psicologia da Universidade de São Paulo	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	12/01/2017 09:45:52	Aceitação de Elaboração de Relatoria	1	Membro do CEP	USP- Instituto de Psicologia da Universidade de São Paulo	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	09/01/2017 11:40:12	Confirmação de Indicação de Relatoria	1	Coordenador	USP- Instituto de Psicologia da Universidade de São Paulo	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	09/01/2017 11:34:40	Indicação de Relatoria	1	Secretária	USP- Instituto de Psicologia da Universidade de São Paulo	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	09/01/2017 11:32:06	Aceitação do PP	1	Secretária	USP- Instituto de Psicologia da Universidade de São Paulo	USP- Instituto de Psicologia da Universidade de São Paulo	
PO	05/01/2017 09:21:16	Submetido pela CONEP para avaliação do CEP	1	Assessor	CONEP	USP- Instituto de Psicologia da Universidade de São Paulo	

Fonte: Maricy Caregnato, 2018

A figura 6 mostra o estado do projeto em que no campo “situação” encontra-se aprovado.

Figura 6 – Estado de aprovado do projeto de pesquisa

LISTA DE PROJETOS DE PESQUISA:									
Tipo ⁺	CAAE ⁺	Versão ⁺	Pesquisador Responsável ⁺	Comitê de Ética ⁺	Instituição ⁺	Origem ⁺	Última Apreciação ⁺	Situação ⁺	Ação
P	63581417.5.0000.5561	1	Maricy Caregnato	5561 - USP- Instituto de Psicologia da Universidade de São Paulo	Instituto de Matemática e Estatística da Universidade de São Paulo	PO	PO	Aprovado	

Fonte: Maricy Caregnato, 2018

Após a aprovação do projeto, ocorreu a liberação do Parecer favorável, conforme exposto a seguir: as figuras 7 a 11 exibem o parecer completo, liberado pelo comitê de ética.

Figura 7 – Parecer completo, liberado pelo comitê de ética - parte 1


<div style="display: flex; justify-content: space-between; align-items: center;"> <div> USP- INSTITUTO DE PSICOLOGIA DA UNIVERSIDADE DE SÃO </div> <div>  </div> </div>												
PARECER CONSUBSTANCIADO DO CEP												
<p>DADOS DO PROJETO DE PESQUISA</p> <p>Título da Pesquisa: Um modelo para detecção de traços de comportamento depressivo em rede social</p> <p>Pesquisador: Maricy Caregnato</p> <p>Área Temática:</p> <p>Versão: 1</p> <p>CAAE: 63581417.5.0000.5561</p> <p>Instituição Proponente: Instituto de Matemática e Estatística da Universidade de São Paulo</p> <p>Patrocinador Principal: Instituto de Matemática e Estatística da Universidade de São Paulo</p> <p>DADOS DO PARECER</p> <p>Número do Parecer: 2.019.886</p> <p>Apresentação do Projeto:</p> <p>Trata-se de projeto de doutorado da autora no Instituto de Matemática e Estatística da Universidade de São Paulo. Pretende propor um modelo para detecção de quadro depressivo por meio de informações extraídas de atributos em rede social, a partir do fato de a depressão ser uma doença frequente entre as doenças cognitivas e requerer atenção porque as perdas relativas ao quadro depressivo podem ser elevadas, e seus efeitos podem ser atenuados quando diagnosticada e tratada. O modelo será limitado a comunidade brasileira adulta a partir dos 21 anos. Inicialmente será feita uma coleta de dados por meio de um aplicativo dentro do Facebook, posteriormente os dados serão tratados e manipulados por algoritmos de aprendizagem de máquina na busca de extração de informações para subsidiar a hipótese e gerar o modelo proposto. O público alvo da pesquisa será limitado a comunidade brasileira adulta a partir dos 18 anos que possuam uma conta na rede social Facebook. Primeiramente acontecerá uma coleta por um período de dois meses. Cada voluntário (usuário da rede que aceita participar) responde o questionário BDI-II e é classificado de acordo com a intensidade da depressão, (ausente, mínima, leve, moderada e grave) formando 5 classes. Além disso, os dados referentes a postagens e curtidas serão coletados para definir um padrão de</p>												
<table border="0" style="width: 100%;"> <tr> <td colspan="2">Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27</td> <td></td> </tr> <tr> <td>Bairro: Cidade Universitária</td> <td>CEP: 05.508-030</td> <td></td> </tr> <tr> <td>UF: SP</td> <td>Município: SÃO PAULO</td> <td></td> </tr> <tr> <td>Telefone: (11)3091-4182</td> <td>E-mail: cep@usp.br</td> <td></td> </tr> </table>	Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27			Bairro: Cidade Universitária	CEP: 05.508-030		UF: SP	Município: SÃO PAULO		Telefone: (11)3091-4182	E-mail: cep@usp.br	
Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27												
Bairro: Cidade Universitária	CEP: 05.508-030											
UF: SP	Município: SÃO PAULO											
Telefone: (11)3091-4182	E-mail: cep@usp.br											

Figura 8 – Parecer completo, liberado pelo comitê de ética - parte 2


<div style="display: flex; justify-content: space-between; align-items: center;"> <div style="text-align: center;"> USP- INSTITUTO DE PSICOLOGIA DA UNIVERSIDADE DE SÃO </div> <div style="text-align: right;">  </div> </div>								
<small>Continuação do Parecer: 2.019.888</small>								
<p>comportamento relacionado a sua frequência de atividades. Posteriormente à etapa da coleta de dados, ocorrerá a fase de análise, onde técnicas de mineração de dados, estatísticas e de aprendizado de máquina serão utilizadas. Os dados serão manipulados por essas técnicas onde cada classe de voluntários terá seu padrão de</p> <p>comportamento e esse padrão será comparado para verificar se pode ser confirmada a hipótese de que é possível identificar correlações entre a classe de depressão e o padrão de comportamento na rede social caracterizado por postagens e curtidas.</p> <p>Objetivo da Pesquisa:</p> <p>Objetivo Primário:</p> <p>Possibilitar a detecção de possíveis comportamentos depressivos pelas correlações entre uma classe de depressão e o seu padrão de comportamento na rede social caracterizado por postagens e curtidas.</p> <p>Objetivo Secundário:</p> <p>Apresentar resultados da utilização de diferentes algoritmos de aprendizagem de máquina em problemas que envolvam análise em dados de redes sociais.</p> <p>Mostrar se o modelo BDI-II - Inventário de depressão de Beck será eficiente na detecção de comportamento depressivo em redes sociais.</p> <p>Avaliação dos Riscos e Benefícios:</p> <p>Sobre os Riscos, os pesquisadores esclarecem: "Existe a possibilidade do participante sentir-se desinformado quanto aos objetivos da pesquisa, podendo gerar um sentimento de insegurança. Para eliminar essa possibilidade um documento com informações detalhadas foi criado e disponibilizado no link: http://projetovivamente.blogspot.com.br/2016/10/sobre-o-aplicativo-e-instrucoes-de-uso.html</p> <p>No que tange a forma de preenchimento do formulário, pode acontecer de o participante sentir-se despreparado com relação a utilização do aplicativo de coleta, gerando assim certo grau de ansiedade. Para resolver esse problema as instruções de uso foram detalhadamente descritas em um documento e disponibilizadas no link: http://projetovivamente.blogspot.com.br/2016/10/sobre-o-aplicativo-e-instrucoes-de-uso.html</p> <p>Referente a Política de privacidade, Termos de serviço e Suporte ao usuário. Existe uma probabilidade de que o participante sinta-se desamparado, para eliminar esse sentimento cada um desses aspectos foi descrito nos links:</p> <p>http://projetovivamente.blogspot.com.br/2016/10/politica-de-privacidade.html</p> <p>http://projetovivamente.blogspot.com.br/2016/10/termos-de-servico.html</p>								
<table style="width: 100%; border: none;"> <tr> <td style="border: none;">Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27</td> <td style="border: none;"></td> </tr> <tr> <td style="border: none;">Bairro: Cidade Universitária</td> <td style="border: none;">CEP: 05.508-030</td> </tr> <tr> <td style="border: none;">UF: SP</td> <td style="border: none;">Município: SÃO PAULO</td> </tr> <tr> <td style="border: none;">Telefone: (11)3091-4182</td> <td style="border: none;">E-mail: oeph.ip@usp.br</td> </tr> </table>	Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27		Bairro: Cidade Universitária	CEP: 05.508-030	UF: SP	Município: SÃO PAULO	Telefone: (11)3091-4182	E-mail: oeph.ip@usp.br
Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27								
Bairro: Cidade Universitária	CEP: 05.508-030							
UF: SP	Município: SÃO PAULO							
Telefone: (11)3091-4182	E-mail: oeph.ip@usp.br							

Figura 9 – Parecer completo, liberado pelo comitê de ética - parte 3


<div style="display: flex; justify-content: space-between; align-items: center;"> <div style="text-align: center;"> USP- INSTITUTO DE PSICOLOGIA DA UNIVERSIDADE DE SÃO </div> <div style="text-align: right;">  </div> </div>								
<small>Continuação do Parecer: 2.019.886</small>								
<p>http://projetovivamente.blogspot.com.br/2016/10/informacoes-de-suporte-ao-usuario-nome.html Respectivamente.</p> <p>Em relação à coleta, armazenamento e manipulação dos dados, esse aspecto pode gerar um sentimento de insegurança referente a exposição dos dados do participante. Para suprimir esses riscos um aplicativo foi desenvolvido sob tecnologias seguras e está operando do lado do servidor; os dados serão armazenados em um banco de dados seguro e pago. E a forma de manipulação dos dados está descrita no link: http://projetovivamente.blogspot.com.br/2016/10/sobre-o-aplicativo-e-instrucoes-de-uso.html</p> <p>O participante também terá a garantia de que a manipulação de seus dados jamais permitirá sua identificação, descrita no Termo de Consentimento Livre e Esclarecido. Sob esse mesmo aspecto, existe a garantia de que o aplicativo de coleta deverá passar pela rigorosa análise de aplicativos e, quando aprovado, seguir a Política da Plataforma do Facebook: https://developers.facebook.com/policy</p> <p>Uma cópia do código fonte do aplicativo encontra-se no github no link: https://github.com/cmaricy/Vivamente</p> <p>A respeito dos Benefícios:</p> <p>"O participante estará contribuindo para a comunidade acadêmica de maneira geral que busca sempre técnicas mais adequadas em busca de melhores resultados, bem como o benefício a toda a comunidade que sofre com problemas de depressão.</p> <p>A comunidade acadêmica, mais especificamente a comunidade que trabalha com pesquisas relativas à mineração de dados em redes sociais, será beneficiada com os resultados dos experimentos, pois é uma área onde existe uma infinidade de ferramentas e técnicas para extrair informação relevante das mais variadas bases de dados para diversos objetivos.</p> <p>A comunidade de desenvolvedores de aplicativos em redes sociais, pois terão um modelo de aplicativo disponível na rede que poderá ser adaptado a objetivos semelhantes.</p> <p>A comunidade acadêmica relacionada a área da saúde estará se beneficiando pois poderá manipular uma ferramenta onde poderá ter resultados relativos a um problema que é a depressão, ao qual podemos destacar:</p> <p>-Do ponto de vista corporativo, identificar precocemente possíveis estados de depressão, evitando a perda de produtividade por parte do empregado, pois a pessoa que apresenta um quadro depressivo considerado grave tem sua capacidade social e produtiva comprometida em 90%; em casos moderados, 40%, e em casos com sintomas leves, 20%.</p>								
<table border="0" style="width: 100%;"> <tr> <td colspan="2">Endereço: Av. Prof. Mello Moraes, 1721 - BL "G" sala 27</td> </tr> <tr> <td>Bairro: Cidade Universitária</td> <td>CEP: 05.508-030</td> </tr> <tr> <td>UF: SP</td> <td>Município: SAO PAULO</td> </tr> <tr> <td>Telefone: (11)3091-4182</td> <td>E-mail: ceph.tp@usp.br</td> </tr> </table>	Endereço: Av. Prof. Mello Moraes, 1721 - BL "G" sala 27		Bairro: Cidade Universitária	CEP: 05.508-030	UF: SP	Município: SAO PAULO	Telefone: (11)3091-4182	E-mail: ceph.tp@usp.br
Endereço: Av. Prof. Mello Moraes, 1721 - BL "G" sala 27								
Bairro: Cidade Universitária	CEP: 05.508-030							
UF: SP	Município: SAO PAULO							
Telefone: (11)3091-4182	E-mail: ceph.tp@usp.br							

Figura 10 – Parecer completo, liberado pelo comitê de ética - parte 4



<div style="display: flex; justify-content: space-between; align-items: center;"> <div style="text-align: center;"> USP- INSTITUTO DE PSICOLOGIA DA UNIVERSIDADE DE SÃO </div> <div style="text-align: right;">  </div> </div>								
<small>Continuação do Parecer: 2.019.886</small>								
<p>-Do ponto de vista econômico, diminuir o custo do tratamento da depressão, tanto para o doente quanto para a sociedade em geral. O custo relacionado com morte prematura e o custo indireto por redução na produtividade e absenteísmo no trabalho é elevado, porém quanto mais cedo a doença for diagnosticada, menos grave ela será, e consequentemente, os resultados do tratamento surtirão efeito mais cedo, diminuindo esse custo.</p> <p>-Do ponto de vista psíquico, evitar perdas como a da memória, pois as pessoas que sofrem de depressão possuem alterações cerebrais quando comparadas às que não apresentam o quadro. O hipocampo, uma pequena parte do cérebro responsável pelo armazenamento da memória, é menor em pessoas que tiveram depressão.</p> <p>Comentários e Considerações sobre a Pesquisa: Pesquisa de relevância social, bem delineada, apresenta detalhadamente os riscos e providências a serem tomadas, bem como os benefícios sociais da pesquisa.</p> <p>Considerações sobre os Termos de apresentação obrigatória: Os Termos de apresentação obrigatória são apresentados adequadamente de modo a permitir a análise ética do projeto, o TCLE está adequado e a pesquisa se dará exclusivamente em ambiente virtual, pela rede social do facebook.</p> <p>Recomendações: Sem recomendações.</p> <p>Conclusões ou Pendências e Lista de Inadequações: O projeto está aprovado com a recomendação de incluir nas informações destinadas aos participantes a referência a serviços públicos de saúde mental.</p> <p>Considerações Finais a critério do CEP: Se o projeto prevê aplicação de TCLE, todas as páginas do documento deverão ser rubricadas pelo pesquisador e pelo voluntário e a última página assinada por ambos, conforme Carta Circular no 003/2011 da CONEP/CNS.</p> <p>Salientamos que o pesquisador deve desenvolver a pesquisa conforme delineada no protocolo aprovado. Eventuais modificações ou emendas ao protocolo devem ser apresentadas ao CEPH de forma clara e sucinta, identificando a parte do protocolo a ser modificada e suas justificativas. Lembramos que esta modificação necessitará de aprovação ética do CEPH antes de ser implementada. De acordo com a Res. CNS 466/12, o pesquisador deve apresentar a este CEP/SMS o relatório final do projeto desenvolvido, conforme preenchimento de Protocolo disponível na página do Comitê de Ética em</p>								
<table border="0" style="width: 100%;"> <tr> <td style="width: 50%;">Endereço: Av. Prof. Mello Moraes, 1721 - BL "G" sala 27</td> <td style="width: 50%;">CEP: 05.508-030</td> </tr> <tr> <td>Bairro: Cidade Universitária</td> <td></td> </tr> <tr> <td>UF: SP</td> <td>Município: SAO PAULO</td> </tr> <tr> <td>Telefone: (11)3091-4182</td> <td>E-mail: oeph.lp@usp.br</td> </tr> </table>	Endereço: Av. Prof. Mello Moraes, 1721 - BL "G" sala 27	CEP: 05.508-030	Bairro: Cidade Universitária		UF: SP	Município: SAO PAULO	Telefone: (11)3091-4182	E-mail: oeph.lp@usp.br
Endereço: Av. Prof. Mello Moraes, 1721 - BL "G" sala 27	CEP: 05.508-030							
Bairro: Cidade Universitária								
UF: SP	Município: SAO PAULO							
Telefone: (11)3091-4182	E-mail: oeph.lp@usp.br							

Figura 11 – Parecer completo, liberado pelo comitê de ética - parte 5

USP- INSTITUTO DE PSICOLOGIA DA UNIVERSIDADE DE SÃO				
<small>Continuação do Parecer: 2.019.888</small>				
<p>Pesquisa com Seres Humanos do IPUSP, do site do IPUSP. Em seguida, o protocolo preenchido deverá ser enviado ao CEPH pela Plataforma Brasil, ícone Notificação, logo que o mesmo estiver concluído.</p>				
<p>Este parecer foi elaborado baseado nos documentos abaixo relacionados:</p>				
Tipo Documento	Arquivo	Postagem	Autor	Situação
Informações Básicas do Projeto	PB_INFORMAÇÕES_BÁSICAS_DO_PROJETO_850505.pdf	04/01/2017 23:47:25		Aceito
Projeto Detalhado / Brochura Investigador	Projeto_de_pesquisa.pdf	04/01/2017 23:45:30	Maricy Caregnato	Aceito
Outros	Declaracao_compromisso_com_resultados_Maricy_Caregnato.pdf	04/01/2017 17:22:45	Maricy Caregnato	Aceito
Declaração de Instituição e Infraestrutura	Demonstrativo_infraestrutura.pdf	04/01/2017 17:19:04	Maricy Caregnato	Aceito
TCLE / Termos de Assentimento / Justificativa de Ausência	TCLE_Maricy_Caregnato.pdf	04/01/2017 17:11:17	Maricy Caregnato	Aceito
Folha de Rosto	Folha_de_rosto_Maricy_Caregnato.pdf	04/01/2017 17:04:01	Maricy Caregnato	Aceito
<p>Situação do Parecer: Aprovado</p>				
<p>Necessita Apreciação da CONEP: Não</p>				
<p>SAO PAULO, 18 de Abril de 2017</p>				
<p>Assinado por: Helena Rinaldi Rosa (Coordenador)</p>				
<p>Endereço: Av. Prof. Mello Moraes, 1721 - Bl. "G" sala 27 Bairro: Cidade Universitária CEP: 05.508-030 UF: SP Município: SAO PAULO Telefone: (11)3091-4182 E-mail: ceph.ip@usp.br</p>				
<small>Página 05 de 05</small>				

Fonte: Maricy Caregnato, 2018